
Neurogaze: Triase Skrining Dini Autisme Berbasis Pola Tatapan untuk Layanan Posyandu

Timotius C. P. Sihombing Raphael Angelo A. Purnama Aqila Malfa Zahira
timotiuspatrick@gmail.com raphael.adikara@gmail.com aqilamalfa@gmail.com

Fakultas Teknologi Maju dan Multidisiplin
Universitas Airlangga

Ringkasan

Autisme paling responsif terhadap intervensi pada usia di bawah tiga tahun, tetapi tinjauan lintas negara melaporkan diagnosis rata-rata pada usia 56 bulan, sekitar 32 bulan setelah keresahan pertama orang tua; angka ini bukan estimasi Indonesia. Instrumen lini pertama punya sensitivitas terbatas, sementara asesmen objektif terpusat di fasilitas mahal. Makalah ini memperkenalkan Neurogaze, prototipe PWA luring untuk riset pengukuran atensi pada tablet Android biasa. Kamera mengestimasi pola pandangan selama stimulus sosial dan menahan sesi yang gagal memenuhi syarat kualitas. Keputusannya berlapis tiga. GeoPref 69 persen adalah satu-satunya kandidat pemicu rujukan dengan titik operasi terbit (1.863 anak usia 12–48 bulan, spesifisitas 98 persen, sensitivitas 17 persen), tetapi rujukan otomatis ditahan karena klip 16,75 detik yang dikirim tidak mereplikasi protokol penuh tempat titik operasi itu diturunkan; enam indeks perilaku dilaporkan deskriptif tanpa skor gabungan; dan lapis gabungan belum dibangun karena bobotnya menuntut balita berlabel. Regresi logistik terkalibrasi yang dievaluasi di makalah ini tidak memutuskan apa pun di produk dan dikurung pada panel riset berpenapis out-of-distribution. Kami mengevaluasi bukti konsep domain sumber pada 547 scanpath dari 54 anak usia sekolah di Prancis, direkam dengan eye-tracker 250 Hz, dengan pemisahan yang dikelompokkan per partisipan tetapi tanpa uji eksternal. Regresi logistik 13 fitur geometri mencapai ROC-AUC tingkat anak 0,823 (95% CI 0,697-0,929) pada data tertahan, sedangkan CNN EfficientNetB0 pada citra yang sama mencapai 0,882 (0,774-0,968) tetapi tidak dapat dijalankan pada perangkat sasaran. Pada proxy degradasi gabungan 30 Hz, derau 1,5°, dropout 20%, dan jitter pose 2°, fitur geometri bertahan pada AUC 0,683 dibandingkan 0,605 untuk 19 fitur yang bergantung pada encoding kinematik eye-tracker. Kontrol negatif memperlihatkan taruhannya: mengganti unit pengelompokan split membuat 41 dari 54 anak muncul di kedua sisi. Audit dataset wajah 2.940 citra menemukan enam dari enam metadata tata kelola tidak tersedia; CNN di atasnya mencapai AUC 0,932, dan justru karena itu dataset dikarantina. Di luar validasi algoritmik, dua gerbang instrumen sudah dituntaskan: Gate A lulus pada 100 sesi dari 25 peserta dewasa lintas tiga perangkat Android dengan galat kalibrasi median 2,2°, completion rate 94 persen, dan frame wajah-iris valid 96,4 persen; Gate B lulus pada 30 perbandingan browser simultan terhadap WebGazer.js 3.5.3, dengan 27 pasangan siap, galat median ternormalisasi 0,040997 dan agreement AOI rata-rata 99,7118 persen hasil rekomputasi dari koordinat mentah. Blok target diketahui Gate A menghasilkan konversi sudut lama 2,36° median dan 3,58° persentil 90 pada 94 sesi lulus, tetapi jarak pandang tidak direkam sehingga angka itu bukan akurasi absolut eksak atau uji tanding terhadap WebGazer. Kontrol positif dewasa menjadi bukti end-to-end utama: 12 peserta, 23 sesi direkam, 15 lulus mutu; 9/11 sesi menonton biasa dan 6/12 sesi pola diproduksi dapat dipakai, dengan aturan demonstrasi menyala pada 0/9 dan 4/6 sesi. Hasil ini adalah manipulation check, bukan sensitivitas, spesifisitas, ASD, atau status klinis peserta; mode demonstrasi tidak mengeluarkan rujukan. Gate C dan Gate D tetap terbuka: belum ada balita, uji kader, validasi Indonesia, wawancara praktisi, atau linkage klinis.

1 Pendahuluan

1.1 Latar belakang

Gangguan spektrum autisme menetap seumur hidup, tetapi lintasan perkembangannya dapat diubah bila intervensi dimulai cukup awal. Uji acak terkendali Early Start Denver Model pada anak 18 sampai 30 bulan mencatat kenaikan skor kognitif 17,6 poin setelah dua tahun, dibandingkan 7,0 poin pada kelompok pembandingan, dengan perubahan terbesar pada anak termuda [1]. Persoalannya, sistem yang ada tidak menemukan anak pada rentang usia itu. Kajian lintas negara melaporkan usia rata-rata diagnosis 55,97 bulan, padahal keresahan pertama orang tua muncul pada 23,64 bulan [2]; jeda 32,33 bulan yang jatuh persis pada periode ketika intervensi paling berdampak. Ketimpangannya lebih tajam di negara berpenghasilan rendah dan menengah, tempat 40 persen individu autistik baru terdiagnosis pada usia sepuluh tahun atau lebih, dibandingkan 15 persen di negara berpenghasilan tinggi. Perbedaan itu muncul di ekor distribusi, dan anak-anak di ekor itulah sasaran produk kami.

Instrumen skrining autisme yang paling luas dipakai adalah Modified Checklist for Autism in Toddlers (M-CHAT), kuesioner yang diisi orang tua. Validasi pada layanan primer melaporkan sensitivitas 49,2 persen dengan spesifisitas 94,2 persen dan nilai prediksi positif 28,9 persen [3]; studi lain pada populasi risiko rendah mencatat nilai prediksi positif 36 persen [4]. Angkanya berbeda antar

validasi, tetapi arahnya konsisten: sebagian anak autistik lolos dari penyaringan. Kinerjanya juga bervariasi menurut jenis kelamin, usia gestasi, dan bahasa anak, sehingga perlu dilengkapi sinyal objektif yang tidak bergantung pada ingatan orang tua.

Indonesia belum punya data prevalensi autisme nasional. Angka yang beredar berasal dari ekstrapolasi negara lain atau studi regional yang metodenya tidak sebanding [5], sementara skrining M-CHAT-R di klinik Jakarta menemukan 3,52 persen anak 16 sampai 30 bulan berisiko tinggi [6]. Kapasitas asesmen spesialis juga terbatas, sehingga menaikkan sensitivitas skrining tanpa memperbaiki kapasitas triase hanya memindahkan masalah menjadi antrean rujukan.

Ada satu aset yang sering diabaikan. Indonesia memiliki 338.881 Posyandu dengan 1.059.466 kader aktif, dan program Stimulasi, Deteksi, dan Intervensi Dini Tumbuh Kembang (SDIDTK) sudah menjadi program pokok Puskesmas yang menjangkau hampir setiap desa setiap bulan [7]. Yang terbatas kapasitas deteksinya, bukan jangkauannya. Studi pemberdayaan kader menemukan pelaksanaan SDIDTK cenderung berhenti pada penimbangan dan pengukuran tinggi badan karena kader belum terlatih mendeteksi penyimpangan tumbuh kembang [8]. Jaringan penyalurnya sudah ada; kemampuan mengukurnya yang belum.

1.2 Solusi yang diusulkan dan kontribusi

Kami mengusulkan Neurogaze (*Neurodivergent + gaze*), alat triase skrining berbasis pola tatapan yang dijalankan kader pada tablet Android biasa. Produk ini tidak menggantikan asesmen klinis dan tidak menyaingi ketepatan alat laboratorium. Perannya melengkapi ceklis dengan pengukuran objektif untuk membantu keputusan rujukan pada titik layanan yang sudah menjangkau seluruh desa. Dibandingkan concept paper babak penyisihan, masalah dan produknya sama; yang bertambah adalah implementasi yang berjalan, validasi algoritmik yang tuntas, dua gerbang instrumen yang sudah lulus pengujian, dan lingkup bukti yang dinyatakan tegas.

Kontribusi makalah ini ada delapan:

- (i) rancangan triase untuk keterbatasan nyata layanan primer Indonesia (perangkat murah, operator bukan klinisi, konektivitas tidak menentu), diwujudkan sebagai PWA luring yang dideploy publik;
- (ii) arsitektur keputusan berlapis yang memisahkan kewenangan dari perhitungan: satu pemicu rujukan yang ambangnya diambil apa adanya dari literatur, satu lapis indeks yang deskriptif dan dilarang digabung oleh tipe datanya sendiri, dan satu lapis gabungan yang sengaja belum dibangun (Bagian 3.3);
- (iii) validasi algoritmik yang tuntas pada 54 anak dengan pemisahan berkelompok per partisipan, disertai kontrol negatif yang memverifikasi splitnya tahan bocor;
- (iv) validasi instrumen yang tuntas pada dua gerbang: Gate A pada 100 sesi dewasa lintas perangkat, pencahayaan, dan penggunaan kacamata, serta Gate B pada 30 perbandingan browser simultan terhadap WebGazer.js;
- (v) perbandingan terkendali antara representasi yang akurat dan yang dapat dijalankan, yaitu CNN scanpath melawan 13 fitur geometri, beserta alasan model ber-AUC lebih tinggi tidak kami pakai;
- (vi) studi degradasi yang memetakan penurunan performa ketika sinyal eye-tracker 250 Hz didekati kamera konsumen, dan yang mendasari penguncian set fitur produksi;
- (vii) audit tata kelola yang menolak sebuah dataset wajah publik meski CNN di atasnya mencapai AUC 0,9324 (Lampiran D);
- (viii) pelaporan bukti berjenjang (Gate A-D) yang *fail-closed*, sehingga produk secara struktural tidak punya jalur untuk menampilkan angka validasi yang datanya belum terkumpul.

1.3 Batasan penelitian

Lima batasan berlaku pada seluruh hasil di makalah ini. Kami menyatakannya di muka agar tidak perlu diulang sebagai pengecualian di tiap bagian.

Pertama, lingkup validasinya algoritmik dan instrumental. Kami menguji tiga hal. Apakah representasi dan model memuat sinyal yang dapat digeneralisasi ke subjek yang belum pernah dilihat. Apakah kamera tablet cukup presisi untuk mengukur arah pandangan (Gate A). Dan apakah aliran pengukurannya sejalan dengan WebGazer.js sebagai referensi proyek (Gate B). Ketiganya sudah selesai. Validasi klinis pada kohort sasaran belum, sebab menuntut pengumpulan data primer pada

balita bersama mitra berizin etik. Gate C dan Gate D karena itu masih terbuka, dan tidak ada klaim akurasi diagnosis di makalah ini.

Kedua, data anchor-nya berpindah domain dari sasaran produk. Dataset Carette berisi anak berusia rata-rata 7,88 tahun dari populasi Prancis yang direkam eye-tracker laboratorium 250 Hz, sedangkan sasaran produk anak 16-30 bulan di Indonesia pada kamera tablet 30 fps. Studi degradasi menjawab sebagian dari perpindahan instrumennya; perpindahan usia dan populasi hanya dapat dijawab kohort prospektif.

Ketiga, ukuran sampelnya kecil untuk standar epidemiologi. Lima puluh empat anak menghasilkan interval kepercayaan lebar dan titik kerja yang tidak stabil, sehingga kami memperlakukan AUC sebagai hasil dan ambang operasional sebagai parameter per lokasi. Performa per subkelompok tidak dapat dilaporkan karena dataset anchor tidak menyediakan demografi.

Keempat, keluarannya rekomendasi rujukan, bukan diagnosis. Sistem tidak menyatakan seorang anak autistik, melainkan bahwa pola atensinya di luar rentang tipikal sehingga layak dinilai tenaga yang berwenang.

Kelima, belum ada satu pun balita dalam bukti apa pun di makalah ini, dan tidak satu pun instrumen yang dipakai divalidasi di Indonesia. Gate A dan Gate B seluruhnya pada peserta dewasa, ambang Lapis A berasal dari kohort Amerika Serikat, dan referensi Gate B divalidasi pada laboratorium di luar Indonesia. Batasan ini tidak dapat ditutup oleh pekerjaan teknis; ia menuntut kohort prospektif lokal, dan konsekuensinya dirinci pada Bagian 6.6.

2 Tinjauan Pustaka

2.1 Atensi visual sebagai penanda perilaku

Kelainan pola pandang adalah penanda perilaku autisme yang paling konsisten. Studi longitudinal pada bayi usia 2 sampai 6 bulan menemukan penurunan fiksasi pada mata yang tidak terjadi pada bayi yang kemudian berkembang tipikal [9], dan anak dengan autisme memandang pola geometris jauh lebih lama dibandingkan adegan sosial [10]. Sinyalnya muncul sebelum kemampuan berbahasa berkembang, sehingga dapat diukur pada usia ketika instrumen berbasis wawancara belum dapat diterapkan.

Preferensi geometrik itulah yang kemudian divalidasi pada skala yang cukup besar untuk melahirkan ambang. Wen dkk. [12] menguji ambang 69 persen waktu fiksasi pada pola geometrik terhadap 1.863 anak usia 12-48 bulan dan melaporkan sensitivitas 17 persen, spesifisitas 98 persen, PPV 81 persen, dan NPV 65 persen. Bentuk angka itu penting dan menentukan seluruh rancangan produk kami: ia menandai subtype, bukan populasi ASD secara keseluruhan, sehingga alat yang dibangun di atasnya hanya sah dipakai untuk menegakkan kecurigaan dan tidak pernah untuk menyingkirkannya.

2.2 Representasi scanpath sebagai citra

Carette dkk. [21] mengusulkan dasar teknis pekerjaan kami: mengubah rekaman eye-tracking menjadi citra, dengan lintasan pandangan sebagai garis dan dinamikanya dikodekan pada kanal warna, yaitu kecepatan, akselerasi, dan jerk, sehingga prediksi menjadi klasifikasi citra. Mereka melaporkan AUC di atas 0,9 dengan jaringan saraf, sementara model non-neural pada makalah yang sama hanya sekitar 0,7. Konsekuensinya jarang disebut: kanal warna itu hanya bermakna pada laju sampling asalnya, sehingga fitur apa pun yang membacanya ikut terikat pada eye-tracker 250 Hz.

2.3 Praproses, fitur, model, dan protokol evaluasi

Empat keputusan metodologis di bawah menentukan angka mana yang berarti, dan rinciannya kami pindahkan ke Lampiran G agar dapat direplikasi tanpa memperpanjang badan makalah.

Praproses. Tujuh tahap berjalan seluruhnya di perangkat: deteksi wajah dan iris lewat MediaPipe Face Landmarker, kalibrasi affine ke koordinat layar, penapisan sampel di luar margin, segmentasi deret pada jeda di atas 180 ms, penghalusan eksponensial dengan resampling 50 ms, pemetaan area minat, dan rasterisasi 640×480 mengikuti konvensi Carette.

Dua kelompok fitur. Sembilan belas fitur terbelah menurut satu hal, yaitu apakah fitur itu membaca kanal warna. Tiga belas fitur geometri hanya membaca posisi piksel bertinta (cakupan, dispersi, pusat perhatian, jarak radial, entropi grid 8×8), sedangkan enam fitur kinematik membaca kecepatan, akselerasi, dan jerk yang terkode pada kanal RGB. Turunan tinggi menguatkan derau pada sampling rendah, jadi kelayakan kelompok kedua di kamera 30 fps harus diputuskan lewat pengukuran, bukan asumsi.

Keluarga model. Lima keluarga model tabular diuji pada kedua set fitur, yaitu regresi logistik yang kami tetapkan sebagai model utama sebelum melihat hasil, SVM kernel RBF, Gaussian Naive Bayes, Random Forest, dan Gradient Boosting, ditambah CNN EfficientNetB0 [22] pada citra scanpath sebagai pembanding representasi.

Kalibrasi dan evaluasi. Skor mentah dikalibrasi Platt pada lipatan validasi saja, dan dua titik kerja dilaporkan berdampingan, yaitu ambang target sensitivitas dan indeks Youden. Evaluasinya memakai GroupKFold bersarang dengan `participant_id` sebagai grup, agregasi probabilitas ke tingkat anak, bootstrap yang meresampel anak dan bukan citra, kontrol negatif kebocoran, serta studi degradasi sebagai proxy perangkat sasaran.

2.4 Instrumen dan produk yang tersedia saat ini

M-CHAT dan KPSP murah serta mudah disebar, tetapi bergantung pada laporan manusia [8]. Pada kutub objektif, EarliPoint memperoleh izin FDA 510(k) untuk anak 16-30 bulan [16], tetapi memerlukan eye-tracker khusus di fasilitas klinis dengan biaya pemeriksaan 599 dolar Amerika [17]. Pembanding digital terdekat SenseToKnow: kamera tablet untuk 23 fenotipe perilaku, dengan studi prospektif pada 475 balita di layanan primer AS melaporkan AUC 0,90 [18], yang membuktikan kelayakan kamera perangkat konsumen. Neurogaze mengambil pilihan berbeda: dioperasikan kader secara luring, memakai stimulus Indonesia, dan menjaga model perilaku tetap terpisah agar dapat diaudit.

2.5 Analisis kesenjangan

Kesenjangan yang kami sasar adalah penerjemahan pengukuran objektif menjadi sistem yang kelak dapat diuji bersama kader tanpa jaringan. Kamera tablet sudah dipakai penelitian lain, tetapi validitas Indonesia dan keterpakaian kader belum diuji. Yang kami tambahkan empat hal: orkestrasi prototipe riset berbasis Posyandu, quality gate yang menahan keputusan ketika pengukuran gagal, laporan yang dapat diaudit, dan disiplin pelaporan bukti yang menolak menampilkan angka sebelum datanya ada. Tabel 7 pada Lampiran E merangkumnya.

3 Metodologi


3.1 Konsep produk dan alur penggunaan

Neurogaze menyatu dengan alur SDIDTK yang sudah berjalan, khususnya pada meja keempat Posyandu. Sasarannya seluruh anak 16-30 bulan yang hadir pada kunjungan terjadwal, dengan sesi pada usia 18 dan 24 bulan; rentang itu berimpit dengan jendela intervensi paling produktif sekaligus dengan indikasi instrumen objektif yang sudah diterima regulator [16]. Sesi tidak dibatasi pada anak yang positif ceklis, sebab sasarannya justru anak yang terlewat instrumen berbasis laporan, sehingga waktu per anak dan beban rujukan masuk sebagai kendala rancangan sejak awal.

Kader mendudukkan anak di depan tablet padaudukan sederhana, lalu memutar stimulus adegan sosial yang memancing atensi bergantian antara wajah manusia dan objek non-sosial. Yang diterima kader adalah kategori tindak lanjut, ringkasan pola pandangan dalam bahasa sederhana, kualitas pengukuran, dan alasan eksplisit bila sistem menahan keputusan. Keputusan akhir tetap pada manusia.

3.2 Arsitektur sistem

Gambar 1 memecah produk menjadi tiga tahap yang berjalan berurutan di dalam browser, ditambah satu gerbang mutu yang berdiri di antara inferensi dan laporan.



Gambar 1: Arsitektur produk Neurogaze. Satu sesi 96 detik pada kamera depan tablet melewati estimasi pandangan, pembentukan scanpath, dan inferensi terkalibrasi, seluruhnya di dalam browser tanpa jaringan. Quality gate berdiri di antara inferensi dan laporan: sesi yang gagal memenuhi cakupan fase, deteksi wajah dan iris, sinkronisasi, atau kontrak sesi menghasilkan status ketiga, yaitu keputusan ditahan disertai alasan yang dapat ditindaklanjuti kader.

Tahap A menyiapkan sesi, yaitu pendudukan anak, kalibrasi grid minimal tujuh posisi, lalu stimulus 96 detik berisi dua belas fase: satu baseline, delapan percobaan isyarat berskor, satu blok preferential-looking 17 detik untuk Lapis A, satu blok panggilan nama 13 detik, dan satu penutup. Tahap B mengubah video menjadi scanpath lewat rantai pada Lampiran G, dan di sinilah risiko teknis terbesar berada; tiap langkahnya punya mode gagal yang berbeda, sehingga quality gate perlu tahu langkah mana yang gagal untuk memberi kader alasan yang dapat ditindaklanjuti. Tahap C menghitung 13 fitur geometri dan menjalankan `model.json` berisi skalar, koefisien regresi logistik, dan kalibrator Platt; keluarannya mengisi panel riset yang dijaga penapis out-of-distribution dan tidak masuk ke jalur keputusan, dengan alasan yang dirinci Bagian 3.3. Pemeriksaan mutunya sengaja dipecah dua waktu: saat perekaman aplikasi hanya memeriksa yang dapat diketahui sebelum pemodelan, sedangkan cakupan fase, sinkronisasi, dan kontrak sesi baru dapat dinilai setelah sesi utuh, sehingga gerbangnya duduk sesudah inferensi dan berwenang membatalkan keluaran model.

3.3 Arsitektur keputusan: tiga lapis yang tidak boleh dikaburkan

Pipeline pada Gambar 1 menjelaskan bagaimana angka dihitung, bukan angka mana yang boleh memutuskan. Keduanya kami pisahkan, sebab mencampurnya adalah cara paling umum sebuah pengukuran deskriptif berubah menjadi klaim klinis tanpa ada yang memutuskannya. Sistem ini punya tiga lapis dengan kewenangan berbeda.

Lapis A, GeoPref. Satu-satunya pemicu rujukan otomatis. Sistem mengukur persentase waktu pandangan berada pada panel pola geometrik selama blok preferential-looking, lalu membandingkannya dengan ambang 69 persen dari Wen dkk. [12]: 1.863 anak usia 12-48 bulan, sensitivitas 17 persen, spesifisitas 98 persen, PPV 81 persen, NPV 65 persen. Ambangnya tidak kami latih, tidak kami optimasi, dan tidak kami geser. Konsekuensinya harus dinyatakan sekeras klaimnya: pada sensitivitas 17 persen, alat ini melewati sebagian besar anak autistik, dan pada NPV 65 persen hasil di bawah ambang hampir tidak mengubah keyakinan. Ini sifat alat *rule-in*, bukan cacat implementasi, dan antarmuka wajib mengatakannya.

Lapis B, profil multi-indeks. Enam indeks perilaku dilaporkan berdampingan tanpa skor gabungan: menghadap ke depan, gerak kepala, laju kedip pada fase sosial dan non-sosial, respons terhadap panggilan nama, dan mengikuti isyarat arah dengan uji tanda dalam sesi. Keluarga indeksnya mengi-

kuti Perochon dkk. [18], dan tiap indeks membawa AUC preseden studi itu sebagai provenance di laporan. Menggabungkannya menjadi satu skor menuntut bobot yang hanya dapat difit pada balita berlabel, yang belum kami punya, sehingga larangannya ditegakkan tipe: `field combinedScore` bertipe `null` dan `combinationRuleStatus` adalah literal `not_fitted_requires_gate_c`.

Lapis C, model gabungan. Belum dibangun, karena alasan yang sama.

Regresi logistik Carette berada di luar ketiganya. Ia tetap dikirim bersama aplikasi karena menjadi dasar seluruh bukti evaluasi pada Bagian 4 dan satu-satunya bukti paritas ujung ke ujung antara implementasi Python dan TypeScript, tetapi tidak punya jalur kode untuk memutuskan apa pun; alasannya pada Bagian 6.2.

Tabel 1 menempatkan tiap lapis terhadap preseden yang membenarkannya. Pola yang kami ikuti sederhana: setiap angka yang berwenang memutuskan harus berasal dari studi pada populasi dan kelas perangkat yang benar, bukan dari data pengembangan kami sendiri.

Preseden	Populasi dan perangkat	Performa terbit	Peran di Neurogaze
GeoPref (Wen dkk. 2022)	1.863 anak, 12-48 bulan; eye-tracker	Sens 17%, spec 98%, PPV 81%, NPV 65%, ambang 69%	Lapis A. Satu-satunya pemicu rujukan otomatis; ambang dipakai apa adanya
SenseToKnow (Perochon dkk. 2023)	475 balita, 17-36 bulan; kamera depan tablet	AUC 0,90; sens 87,8%, spec 80,8%	Lapis B. Sumber keluarga indeks dan target Gate C
EarliPoint (FDA 510(k) 2022)	16-30 bulan; eye-tracker khusus di klinik	Izin regulator; 599 USD per pemeriksaan	Pembandingan kelayakan, bukan sumber ambang
WebGazer (Papoutsaki dkk. 2016; Steffan dkk. 2024)	Webcam; divalidasi ManyBabies pada 125 anak 18-27 bulan, 16 lab	Galat 4,17°; attrition balita 42%	Referensi Gate B dan dasar ekspektasi penyelesaian sesi

Tabel 1: Preseden yang menopang tiap lapis keputusan. Tidak satu pun ambang keputusan produk berasal dari data pengembangan kami: Lapis A memakai ambang terbit Wen dkk. tanpa penyetelan, Lapis B melaporkan indeks secara deskriptif dengan AUC preseden sebagai provenance, dan target Gate C diambil dari performa terbit SenseToKnow alih-alih dikarang.

Satu batasan protokol berlaku pada Lapis A dan harus dibaca bersama ambangnya. Ambang 69 persen sudah diterapkan pada dua tes yang berbeda, dan keduanya tidak berbagi preseden. Wen dkk. [12] memvalidasinya pada *GeoPref* asli berdurasi 62,22 detik (Tobii T120, 1280×1024 , dua AOI 525×363 piksel) dan melaporkan sensitivitas 17 persen serta spesifisitas 98 persen pada 1.863 anak usia 12-48 bulan. Moore dkk. [11] membawa ambang yang sama ke *Complex Social GeoPref* berdurasi 90 detik—sebagai pilihan konsistensi, bukan hasil optimasi ulang—dan melaporkan sensitivitas 18 persen, spesifisitas 97 persen, serta AUC 0,74 pada sampel yang jauh lebih kecil.

Yang berjalan pada aplikasi ini bukan salah satu dari keduanya, melainkan cuplikan 16,75 detik dari video contoh Complex Social yang diterbitkan sebagai Additional file 2 milik Moore dkk. Cuplikan itu memuat satu dari lima adegan dan berdurasi seperlima protokol terbitnya. Aplikasi karena itu menyetel `validatedProtocol` bernilai `false` dan *menahan* ambangnya: sesi melaporkan persentase terukur, menyatakan protokolnya dipersingkat, dan tidak memicu rujukan. Tiap aset stimulus pada `app/src/geopref/stimulusMeta.ts` membawa preseden operasionalnya sendiri, sehingga angka Wen dkk. tidak dapat menempel pada sesi Complex Social maupun sebaliknya.

Tiga sifat aset itu perlu dinyatakan agar tidak terbaca sebagai cacat implementasi. Pertama, klipnya *tidak bersuara*, dan itu memang protokolnya: metode Moore dkk. menyatakan bahwa stimulusnya tidak memuat audio. Kedua, panel sosial dan geometriknya duduk di dalam bingkai hitam 640×360 dan hanya menempati 19,8 persen luas bingkai, sedangkan dua AOI pada Wen dkk. menempati 29,1 persen luas layar; presentasi di perangkat karena itu memangkas kotak hitam agar sudut pandang yang disubtensi mendekati angka terbit. Ketiga, integritas berkasnya dijaga SHA-256 yang tercatat pada manifes stimulus.

3.4 Stimulus blok isyarat: kenapa aktor vektor

Blok isyarat arah memakai aktor yang digambar sebagai SVG dan dianimasikan lewat CSS, bukan rekaman aktor manusia. Karena blok ini menempati separuh baterai dan memasok satu dari dua sinyal keputusan yang benar-benar dapat dinilai di lapangan, pilihan itu perlu dipertahankan dengan bukti.

Yang memberatkan perlu dinyatakan lebih dulu. Tinjauan stimulus eye-tracking untuk joint attention melaporkan perbedaan antar-kelompok yang lebih tegas pada stimulus beragen manusia dibandingkan agen animasi. Untuk perbandingan antar-kelompok, agen animasi kemungkinan memperkecil efek yang hendak diukur. Yang membuat hal itu tidak membatalkan pilihan ini adalah bentuk sinyalnya: yang kami ambil dari blok ini bukan perbandingan antar-kelompok, melainkan kontras dalam-subjek—tatapan ke target sesudah isyarat dibanding sebelum isyarat, pada anak yang sama dan aktor yang sama, di dalam percobaan yang sama. Uji tanda satu sisi pada delapan percobaan tidak menuntut norma populasi.

Wajah skematik memang memicu *gaze following*. Bayi baru lahir membedakan tatapan langsung dari tatapan menyamping pada wajah skematik dan berpindah lebih cepat ke target periferifal ketika gerak pupil terlihat [14]. Efek itu dibawa oleh sifat perseptual tertentu, bukan oleh keberadaan wajah secara umum, dan dua di antaranya merupakan syarat rancangan yang dapat diuji. Pertama, polaritas kontras mata: isyarat bergantung pada pola lazim pupil gelap di atas sklera terang, dan polaritas terbalik menghasilkan efek yang jauh lebih lemah [15]. Kedua, gerak pupil harus terlihat; wajah yang sekadar digambar sudah menghadap ke samping bukan stimulus yang sama. Aset kami memenuhi keduanya—sklera #ffffd7 melawan pupil #16181b, dan bola mata bergeser 16 piksel pada onset dengan transisi 240 ms berjeda 50 ms sehingga mata berangkat mendahului kepala dan tangan—dan keduanya dijaga uji kontrak, sehingga penataan ulang gaya visual tidak dapat mencabutnya diam-diam. Struktur percobaannya sendiri mengikuti paradigma *responding joint attention* pada balita [13], dengan epok ostensif yang memulihkan kontak mata sebelum ada informasi arah sama sekali.

Alasan operasionalnya juga bukan sekadar kemudahan. Onset jatuh pada milidetik yang dideklarasikan protokol di semua tablet tanpa bergantung pada dekoder atau frame yang jatuh, dan analisis pra/pasca-isyarat bergantung persis pada ketepatan itu. Asetnya kecil dan berjalan luring penuh, stimulusnya berupa kode berversi yang dapat di-*diff* alih-alih gumpalan biner, dan tidak ada anak yang perlu direkam sehingga tidak ada persoalan izin maupun privasi rekaman.

Batasnya tetap harus dinyatakan: tidak ada satu pun bukti bahwa balita merespons aktor ini. Yang ada adalah paradigma terbit, sifat perseptual yang sesuai literatur, dan rancangan yang dijaga uji. Apakah balita benar-benar mengikuti isyaratnya adalah pertanyaan Gate C.

3.5 Tidak ada pengukuran yang melintasi batas medium

Satu sesi menampilkan dua dunia visual: klip video terbit pada blok pilihan tontonan, dan aktor vektor pada sisanya. Perpindahan itu terlihat oleh peserta, dan pertanyaan yang tepat bukan apakah tampilannya menyambung melainkan apakah ada besaran yang dihitung melintasi sambungannya. Preferensi geometrik dihitung seluruhnya di dalam klip oleh modulnya sendiri; mengikuti isyarat membandingkan pasca-isyarat dengan pra-isyarat di dalam percobaan vektor yang sama; respons nama adalah deteksi peristiwa di dalam blok vektor. Tidak satu pun melintasi batas itu.

Satu pengecualian sempat ada dan karena itu dicabut. Diferensial kedipan membandingkan fase aktor dengan blok video, sehingga kontras “sosial lawan non-sosial” tercampur penuh dengan “vektor lawan video nyata”, dengan arah bias yang sistematis. Ditambah jendela 16,75 detik yang mengkuantisasi laju kedip pada kelipatan 3,6 per menit, selisih yang terukur didominasi derau pencacahan. Indeks itu tetap dilaporkan secara deskriptif tetapi tidak lagi menjadi sinyal keputusan.

3.6 Data

Pengembangan memakai dua dataset publik, satu dipakai dan satu ditolak lewat audit, serta satu rancangan data prospektif untuk tahap deployment.

Dataset scanpath (dipakai). Autism Eye Tracking Dataset dari Carette dkk. [21] berisi 547 citra scanpath beresolusi 640×480 dari 54 partisipan, terdiri atas 26 anak ASD dan 28 kontrol, berusia

rata-rata 7,88 tahun dan direkam dengan eye-tracker SMI Red-m 250 Hz. Seorang anak menyumbang antara 1 dan 23 rekaman dengan median 10, sehingga rekaman berulang bukan pengamatan independen dan seluruh evaluasi wajib dikelompokkan per anak. Dataset ini menjadi anchor validasi algoritmik kami, dan seluruh 54 anaknya dipakai: tiap anak masuk ke lipatan latih, lipatan validasi, dan tepat satu kali ke lipatan uji tertahan sesuai Bagian 3.8. Ukuran sampelnya kecil untuk standar epidemiologi, dan kami menjawabnya dengan interval kepercayaan yang meresampel anak.

Dataset wajah (ditolak). Sebuah dataset citra wajah statis publik berisi 2.940 JPEG berlabel *Autistic* dan *Non_Autistic*, masing-masing 1.470 citra. Kami menolaknya meski CNN yang kami latih di atasnya mencapai AUC 0,9324, angka tertinggi di seluruh proyek ini. Berkasnya bersih secara teknis; yang gagal tata kelolanya, dengan enam dari enam metadata tidak tersedia. Ketidadaan identitas partisipan saja sudah cukup membuat evaluasi apa pun tidak dapat ditafsirkan, sebab tidak ada cara membuktikan foto orang yang sama tidak menyeberang split. Dataset dikarantina dan tidak pernah menyentuh skor Neurogaze. Yang ditolak dataset ini, bukan modalitas wajah dan kepala. Lampiran D memuat audit lengkapnya.

3.7 Pendekatan pemodelan

Gambar 6 pada Lampiran G merangkum enam tahap penelitian, dari citra scanpath sampai model yang dibekukan, beserta metode yang dipakai di tiap tahap.

Lintasan pandangan dirender sebagai raster 640×480 lalu diringkas menjadi 13 fitur geometri ter-tafsir (Bagian 7). Enam fitur kinematik Carette tidak dipakai pada produk: keenamnya bergantung pada kanal warna *velocity-acceleration-jerk* dari eye-tracker 250 Hz dan tidak dapat direkonstruksi dengan sah dari kamera 30 fps. Sebagai pembandingan representasi, kami juga melatih CNN Efficient-NetB0 [22] berpretrain ImageNet langsung pada citra scanpath, dengan konfigurasi pada Bagian 7.

3.8 Protokol evaluasi: pemisahan latih, validasi, dan uji

Unit keputusan produk adalah anak, sehingga endpoint utamanya AUC tingkat anak dan seluruh pemisahan data terjadi pada tingkat anak. Dasarnya terukur: rata-rata 38,2 persen variasi fitur berada pada tingkat antarpartisipan.

Kami memakai `GroupKFold` bersarang dengan ID partisipan sebagai grup, memisahkan data menjadi tiga peran: empat lipatan dalam untuk melatih scaler dan koefisien, satu lipatan dalam yang ditahan untuk memasang kalibrator Platt dan memilih ambang pada target sensitivitas 0,9, serta lima lipatan luar sebagai uji tertahan dengan tiap anak muncul tepat satu kali. Susunan ini membuat setiap angka performa pada Bagian 4 berasal dari anak yang tidak dilihat model saat dilatih maupun saat dikalibrasi. Assertion otomatis menghentikan pipeline bila irisan `participant_id` antar ketiga peran tidak nol, dan hasilnya nol di seluruh lipatan; Bagian 4.6 melaporkan apa yang terjadi bila unit pengelompokan ini salah dipilih.


Ambangnya condong ke sensitivitas tinggi karena asimetri biaya skrining: melewatkan anak autistik berarti kehilangan jendela intervensi yang kerugiannya sering permanen, sedangkan merujuk anak tipikal menimbulkan kecemasan dan biaya asesmen yang masih dapat dipulihkan.

3.9 Implementasi produk

Neurogaze berjalan sebagai Progressive Web App. MediaPipe Face Landmarker dimuat sebagai WASM lokal, model statistik disimpan sebagai `model.json`, dan aset stimulus di-cache service worker sehingga alur inti berjalan tanpa jaringan setelah kunjungan pertama. Aplikasi memisahkan empat kontrak: replay deterministik untuk demonstrasi, sesi anak yang melaporkan pengukuran Lapis A dan Lapis B tanpa skor gabungan, Gate A untuk audit perangkat pada peserta dewasa, dan halaman bukti Gate B untuk hasil agreement terhadap WebGazer.js. Laporan sesi dapat dicetak sebagai serah terima satu halaman untuk Puskesmas, dan log auditnya tinggal di memori sampai operator memilih mengeksport atau menghapusnya.

3.10 Lingkup validasi makalah ini dan tahap sesudahnya

Produk skrining melewati beberapa jenis validasi, dan mencampuradukkannya adalah sumber klaim berlebih yang paling umum. Kami memisahkannya jadi empat tingkat: validasi algoritmik menguji



Gambar 2: Hasil utama pada 547 scanpath dari 54 anak. (a) Ukuran efek antar kelompok pada tingkat partisipan; hijau menandai fitur geometri, jingga menandai fitur kinematik yang bergantung pada encoding eye-tracker, garis titik menandai ambang efek besar $|d| = 0,8$. (b) AUC tingkat anak di bawah proxy degradasi perangkat, dengan pita menunjukkan 95% CI set geometri. (c) Jumlah anak yang menyeberang batas split ketika unit pengelompokan salah dipilih.

generalisasi ke subjek baru; Gate A menguji presisi pengukuran perangkat; Gate B menguji agreement terhadap WebGazer.js; Gate C dan D menguji kemampuan skrining dan operasional pada kohort sasaran. Makalah ini menuntaskan tiga tingkat pertama: validasi algoritmik, Gate A, dan Gate B. Gate C dan Gate D tetap terbuka: bukti sekunder dan dasar prosedur membantu merancang tahap berikutnya, tetapi tidak sama dengan validasi klinis atau operasional yang selesai. Kriteria seluruh tingkat dicatat pada Lampiran A agar sasarnya tidak dapat digeser belakangan.

Kriteria semacam itu mudah ditulis dan mudah dilanggar, jadi kami menegakkannya di kode. Agregator Gate B hanya menerima kontrak WebGazer v3, mempertahankan pasangan yang ditahan dalam denominator, dan menghitung keputusan dari lima kriteria yang tercatat. Halaman bukti publik /validation membaca snapshot yang angkanya sama dengan ringkasan kanonis, sedangkan manifest SHA-256 mengunci seluruh 130 ekspor mentah Gate A dan Gate B.

4 Hasil

4.1 Sinyal geometri scanpath pada tingkat anak

Perbedaan antar kelompok muncul dengan ukuran efek besar pada tingkat partisipan (Gambar 2a). Delapan dari sebelas fitur dengan efek terbesar berasal dari set geometri, dipimpin jumlah sel grid aktif ($d = 1,69$), fraksi tinta ($d = 1,50$), rentang vertikal ($d = 1,48$), dan entropi grid ($d = 1,47$). Arahnya konsisten: anak dengan autisme menyapu bidang layar lebih luas dan lebih merata, sementara anak tipikal memusatkan pandangan pada zona tengah. Dua fitur kinematik terkuat, kecepatan rata-rata ($d = 1,22$) dan rasio fiksasi ($d = -1,15$), berada di bawah empat fitur geometri teratas.

4.2 Model yang di-deploy: regresi logistik 13 fitur

Kami membekukan regresi logistik 13 fitur geometri sebagai model MVP, dengan kalibrasi Platt dipasang pada lipatan validasi dan pengujian pada lipatan luar yang tertahan. Pada data uji tertahan, model mencapai AUC tingkat anak 0,8228 (95% CI 0,6974-0,9290) dibandingkan 0,8324 (0,7069-0,9368) untuk set 19 fitur penuh (Tabel 4 pada Lampiran E). Selisih berpasangannya $-0,0137$ dengan 95% CI $[-0,0593; 0,0247]$, jadi keunggulan set penuh pada data bersih berada di dalam derau. Set geometri menang atau imbang pada empat dari lima keluarga model. Kalibrasi probabilitasnya wajar, dengan Brier tingkat anak 0,1758 dan kemiringan 1,54.

Target sensitivitas 0,9 melahirkan ambang 0,2243, yang memberi sensitivitas 88,5 persen dengan spesifisitas 17,9 persen dan rentang bootstrap ambang yang lebar (0,1478-0,4537). Spesifisitas se-rendah itu konsekuensi aritmetika: pada 54 anak, memaksa sensitivitas mendekati 0,9 menggeser titik kerja ke ujung kurva tempat hampir semua anak dirujuk. Peringkat model jauh lebih stabil daripada titik kerjanya, sehingga AUC yang kami perlakukan sebagai hasil dan ambang operasional sebagai parameter per lokasi.

4.3 Titik kerja, matriks kebingungan, dan analisis kesalahan

Satu angka sensitivitas dan satu angka spesifisitas menyembunyikan ruang keputusan yang sebenarnya tersedia, jadi kami memetakannya. Pada ambang target sensitivitas (0,2243), 46 dari 54 anak dirujuk: model menangkap 23 dari 26 anak ASD tetapi ikut menandai 23 dari 28 kontrol. Pada titik kerja seimbang menurut indeks Youden (0,4985), sensitivitasnya 0,731 dan spesifisitasnya 0,821 dengan 25 anak dirujuk. Tabel 8 di Lampiran E merinci titik-titik di antaranya, termasuk jumlah anak dirujuk per 100 anak diskriminasi, yaitu besaran yang menentukan apakah sebuah ambang dapat dijalankan Puskesmas dengan kapasitas rujukan tertentu. Gambar 4 pada Lampiran F menampilkan matriks kebingungan kedua titik kerja itu.

Analisis kesalahan pada titik kerja seimbang berujung pada satu perubahan rancangan produk. Delapan anak ASD terlewat dan lima kontrol salah ditandai, seluruhnya pada probabilitas 0,169 sampai 0,628, yaitu di sekitar ambang; tidak ada kesalahan berkeyakinan tinggi. Gambar 5 pada Lampiran F menampilkan scanpath-nya, dan polanya terbaca tanpa statistik: anak ASD yang terlewat punya lintasan pendek dan jarang, sedangkan kontrol yang salah ditandai punya lintasan yang tidak biasa luas. Angkanya sejalan. Pada 45 anak yang citranya dapat kami petakan kembali ke rekaman aslinya, korelasi Spearman antara fraksi tinta dan probabilitas keluaran model adalah 0,927, dan fraksi tinta anak ASD yang terlewat rata-rata 0,46 persen berbanding 1,94 persen pada yang terdeteksi benar (Mann-Whitney $p = 0,0008$). Keluaran model riset Carrette, dengan kata lain, hampir sepenuhnya monoton terhadap seberapa luas layar disapu pandangan.

Konsekuensinya menyangkut keselamatan. Rekaman yang pendek, terputus, atau tidak terlacak menghasilkan scanpath jarang, dan scanpath jarang menghasilkan skor rendah, yaitu keluaran “pan-tau”. Bila anaknya berisiko, itulah keputusan yang paling berbahaya, dan anak yang paling sulit direkam bisa jadi anak yang paling mungkin luput. Ambang cakupan pada quality gate karena itu berfungsi ganda, sebagai penjaga mutu data sekaligus pengaman klinis: sesi yang tidak memenuhi cakupan minimum wajib ditahan dan diulang, tidak diteruskan menjadi skor rendah. Lampiran A menjadikan verifikasi endpoint wajib pada kohort prospektif.

4.4 Dampak operasional empat titik kerja

Sensitivitas dan spesifisitas adalah properti kurva; yang menentukan sebuah alat dapat dijalankan atau tidak adalah berapa banyak anak yang dirujuk dan berapa rujukan yang dibutuhkan untuk menemukan satu kasus benar. Kami memproyeksikan keempat titik kerja yang tersedia ke satu antrean Posyandu hipotetis: 1.000 anak, prevalensi 1 persen, dan coverage teknis 90 persen. Angka coverage-nya asumsi perencanaan yang lebih longgar daripada attrition 42 persen yang dilaporkan Steffan dkk. [19], dan harus diuji di lapangan. Tabel 2 memuat hasilnya; artefaknya `research/hasil/gate_c_simulation.json`, dan lengan regresi logistiknya membaca `model.json` sehingga tidak dapat melenceng dari model yang benar-benar dikirim.

Titik kerja	Sens	Spec	Rujukan	PPV	Rujukan/kasus
Regresi logistik, sens 0,9	0,923	0,179	82,2%	0,011	89,1
Regresi logistik, Youden	0,731	0,821	18,4%	0,040	25,2
GeoPref 69% (aktif)	0,170	0,980	2,2%	0,079	12,6
Target Gate C (preseden)	0,878	0,808	19,9%	0,044	22,6

Tabel 2: Proyeksi beban rujukan empat titik kerja pada 1.000 anak, prevalensi 1 persen, coverage teknis 90 persen. Kolom *Rujukan* adalah persentase anak yang dapat dinilai dan berakhir dirujuk; kolom *Rujukan/kasus* adalah jumlah rujukan yang dibutuhkan untuk menemukan satu kasus benar. Simulasi perencanaan, bukan hasil klinis: tidak ada balita prospektif yang direkrut, dan dua lengan pertama berasal dari 54 partisipan usia sekolah pada 250 Hz sehingga tidak berlaku untuk balita. Baris ketiga adalah titik kerja yang benar-benar aktif di produk.

Tabel ini menjelaskan dalam satu baris kenapa alat *rule-in* adalah bentuk yang benar untuk antrean Posyandu. Titik sensitivitas 0,9 adalah yang paling menggoda dilaporkan, dan ia merujuk 740 dari 1.000 anak dengan 89 rujukan per satu kasus benar; tidak ada Puskesmas yang kapasitas rujukannya menyerap itu, dan alat yang menandai empat dari lima anak akan berhenti dipakai sebelum kasus pertamanya ditemukan. Titik GeoPref merujuk 19 anak pada 12,6 rujukan per kasus benar. Ia

menemukan paling sedikit kasus secara absolut, yaitu 1,5 dari 9 yang ada pada kohort ini, dan itu harga yang dibayar untuk spesifisitas 98 persen. Pilihan produknya karena itu bukan pilihan performa melainkan pilihan peran: mendampingi SDIDTK yang menangkap luas dengan spesifisitas rendah, bukan menggantikannya.

Dua catatan menutup pembacaan tabel ini. Lengan target Gate C bukan performa Neurogaze melainkan performa instrumen lain pada kelas perangkat yang sama, ditulis sebagai sasaran yang harus dikejar. Dan tidak satu pun lengan boleh memakai angka CNN, sebab model itu tidak dapat dijalankan pada perangkat sasaran, sehingga memasukkannya berarti memproyeksikan biaya operasional sebuah sistem yang tidak ada.

4.5 Batas atas representasi: CNN pada citra scanpath

CNN EfficientNetB0 pada citra scanpath yang sama mencapai AUC tingkat anak 0,8819 (95% CI 0,7738-0,9681), dengan rata-rata per fold 0,8848 dan simpangan baku 0,1289. Pada ambang 0,476 dari lipatan validasi, balanced accuracy-nya 0,7981 dengan sensitivitas 0,8462 dan spesifisitas 0,7500, jauh lebih seimbang daripada regresi logistik; 11 dari 54 anak salah diklasifikasikan, seluruhnya pada probabilitas 0,23 sampai 0,61. Ablasi fine-tuning memberi hasil nol: membuka 25 persen lapisan teratas hanya mengubah AUC validasi sebesar $+0,0009 \pm 0,0027$, tidak dapat dibedakan dari derau pada 54 anak. Selisih 0,059 AUC terhadap model riset Carette adalah harga yang kami bayar dengan sadar; alasannya pada Bagian 6.2.

4.6 Verifikasi integritas split

Klaim bahwa data uji benar-benar tertahan hanya bermakna bila diuji. Kami menjalankan ulang pipeline CNN yang identik dan mengganti satu hal saja, yaitu unit pengelompokan split, dari ID partisipan menjadi klaster duplikat visual berbasis dHash, sebagai kontrol negatif terhadap protokol Bagian 3.8.

Hasilnya, seperti pada Gambar 2c, 41 dari 54 anak muncul di sisi latih dan sisi uji sekaligus, 39 anak menyeberang batas latih/validasi, dan 35 anak menyeberang batas validasi/uji; dengan pengelompokan per anak ketiganya nol. AUC protokol bocor 0,8351 berbanding 0,8848 pada protokol benar. Arahnya berlawanan dengan dugaan umum, dan pada simpangan baku antar fold 0,1289 selisih itu tidak dapat dibedakan dari derau, jadi kami tidak menyimpulkan apa pun tentang besar maupun arah biasanya. Kesimpulan kami lebih mendasar: ketika 41 anak yang sama muncul di kedua sisi, angkanya berhenti menjawab pertanyaan yang ingin dijawab produk, yaitu performa pada anak yang belum pernah dilihat.

4.7 Ketahanan terhadap degradasi perangkat

Studi degradasi menambahkan derau posisi, sparsifikasi raster sebagai proxy laju sampling, dropout, dan jitter pose, dengan 200 replikasi bootstrap per kondisi dan tiga seed. Gambar 2b dan Tabel 9 di Lampiran E memuat hasil lengkapnya. Terhadap derau, dropout, dan jitter kedua set fitur turun hampir sejajar; terhadap penurunan laju sampling keduanya berpisah, dan pada kondisi gabungan yang meniru perangkat sasaran geometri mencapai 0,6827 (95% CI 0,5384-0,8014) berbanding 0,6049 untuk set penuh.

Hasil itu mengunci 13 fitur geometri untuk MVP. Geometri satu-satunya representasi yang dapat dihitung dari aliran (x, y, t) 30 fps di perangkat sasaran, dan justru pada kondisi yang menyerupai perangkat itu ia unggul: selisihnya di sana $(+0,0778)$ jauh lebih besar daripada keunggulan set penuh pada data bersih $(-0,0096)$.

4.8 Hasil sistem dan reproduktibilitas

Paritas numerik antara implementasi Python dan TypeScript lulus pada toleransi 10^{-12} , baik untuk nilai fitur maupun probabilitas model, dengan rangkaian uji hijau penuh. Benchmark rantai raster sampai inferensi memberi median 4,93 ms pada desktop referensi. Rincian uji, kontrak luring, dan angka latensi ada pada Lampiran E.

Analisis desimasi temporal terpisah memakai 27 sesi Gate B yang membawa stempel waktu nyata. Saat laju efektif turun dari 26,16 menjadi 13,08 Hz, median drift relatif fitur kinematik adalah 69,35 persen dan fitur geometri 1,64 persen. Kedua angka ini mengukur drift fitur, bukan akurasi atau robustness klasifikasi. Enam dari 13 fitur geometri tetap memiliki Spearman di bawah 0,8 pada 13,08 Hz; pada 6,54 Hz median Spearman geometri turun menjadi 0,4426 dan beberapa fitur menunjukkan drift besar. Hasil ini mendukung pemilihan keluarga geometri tanpa menyatakan bahwa seluruh fiturnya stabil.

4.9 Gate A: validasi instrumen pada kohort dewasa

Gate A menguji apakah kamera tablet biasa dapat mendeteksi wajah dan iris, membedakan arah kiri, tengah, dan kanan, menjalankan kalibrasi beserta seluruh fase stimulus, menahan hasil ketika mutunya gagal, dan tetap bekerja tanpa jaringan. Gerbang ini tidak mengeluarkan skor risiko dan tidak menguji autisme.

Dua puluh lima peserta dewasa menjalani empat sesi per orang pada tiga jenis perangkat Android, mencakup kondisi cahaya normal dan redup serta peserta dengan dan tanpa kacamata, sehingga terkumpul 100 sesi lengkap. Hasilnya 94 dari 100 sesi selesai, galat median 2,2°, wajah dan mata terbaca pada 96,4 persen frame, dropout sinyal pandangan 3,6 persen, dan seluruh fungsi inti berjalan lancar tanpa satu pun crash. Tabel 5 pada Lampiran E merinci sebarannya menurut kondisi pengujian.

Pada 94 dari 100 sesi yang lulus, blok target diketahui menghasilkan konversi sudut lama dengan median 2,36° dan persentil 90 sebesar 3,58°. Jarak pandang tiap sesi tidak direkam, sehingga angka ini memberi konteks teknis tetapi bukan akurasi absolut eksak. WebGazer melaporkan 4,17° pada perangkat dan protokol berbeda [20]; keduanya bukan uji tanding. Blok target diketahui head-to-head Gate B belum direkam.

Polanya mengikuti mutu deteksi iris. Cahaya redup dan lensa kacamata sama-sama menurunkan mutu itu, dan di situlah galat median naik ke kisaran 2,8-2,9° sementara tingkat keberhasilan sesi turun ke 87-88 persen. Enam sesi tidak menghasilkan laporan sama sekali, yaitu tiga karena pantulan kacamata, dua karena wajah terlalu miring, dan satu karena orientasi layar berubah setelah kalibrasi. Seluruh kegagalan itu dikenali sistem dan diarahkan untuk dikoreksi atau dikalibrasi ulang, bukan diteruskan menjadi skor rendah.

Terhadap kriteria pra-tetap Lampiran A, keempat ambangnya terpenuhi: galat median 2,2° terhadap batas $\leq 3^\circ$, frame valid 96,4 persen terhadap batas ≥ 85 persen, penyelesaian sesi 94 persen terhadap batas ≥ 90 persen, serta nol sesi invalid yang menghasilkan skor risiko. **Status Gate A: lulus.**

4.10 Gate B: agreement terhadap WebGazer.js

Gate B membandingkan aliran gaze Neurogaze dengan implementasi referensi WebGazer.js 3.5.3 yang direkam secara simultan di browser. Pemilihan pembandingnya bukan soal kemudahan: WebGazer adalah metode webcam yang divalidasi ManyBabies untuk balita usia 18-27 bulan pada 125 anak di 16 laboratorium [19], sehingga ia satu-satunya referensi terbuka yang punya bukti pada rentang usia yang mendekati sasaran produk. Studi yang sama melaporkan attrition 42 persen, dan angka itu kami pakai sebagai dasar ekspektasi penyelesaian sesi balita serta alasan keadaan ditahan dirancang sebagai hasil kelas satu, bukan sebagai kegagalan. Kontrak referensinya adalah callback `setGazeListener` dengan data dan waktu berjalan pada ruang koordinat piksel CSS. Yang WebGazer bukan ground truth atau standar emas. Yang dibandingkan adalah galat koordinat ternormalisasi, agreement area of interest (AOI), AOI utama, dan 13 fitur geometri. Pengujian ini mengukur agreement perangkat lunak, bukan kemampuan mendiagnosis ASD atau kesetaraan dengan eye-tracker laboratorium.

Tiga puluh pasangan terekam. Dua puluh tujuh berstatus siap dan tiga ditahan, sehingga valid pair rate 90 persen dan retry rate 10 persen. Galat median antaraliran adalah 44,159 piksel atau 0,040997 pada skala ternormalisasi. Seluruh jarak ini direderivasi dari koordinat mentah oleh `research/recompute_gate_b.py` dan direproduksi sampai 0,001 piksel. Agreement AOI rata-rata hasil rekompulasi adalah 99,7118 persen; nilai yang ditulis browser saat perekaman 99,7574 persen, dan selisihnya berasal dari empat pasangan yang masing-masing memiliki satu sampel tepat

di luar kotak AOI menurut `neurogaze-aoi-v3.1.0`. Selisih itu diterbitkan di `gate_b_summary.json` alih-alih didamaikan. AOI utama cocok pada seluruh 27 pasangan siap. Angka agreement setinggi ini perlu dibaca dengan hati-hati: kotak AOI selebar 28 persen layar sementara galat median antarliran hanya 4,1 persen lebar layar, sehingga kesepakatan tinggi nyaris tidak terhindarkan dan bukan bukti akurasi. Rata-rata ICC(A,1) untuk 13 fitur adalah 0,505043; nilai ini dilaporkan secara deskriptif dan bukan kriteria kelulusan.

Seluruh lima kriteria yang tercatat terpenuhi: 30 pasangan terhadap batas ≥ 30 , valid pair rate 90 persen terhadap batas ≥ 90 persen, galat median ternormalisasi 0,040997 terhadap batas $\leq 0,05$, agreement AOI rata-rata 99,7118 persen terhadap batas ≥ 95 persen, dan agreement AOI utama 100 persen terhadap batas ≥ 95 persen. **Status Gate B: lulus.**

Kesimpulan ini terbatas pada agreement terhadap implementasi referensi WebGazer.js dalam kohort yang terekam. Generalisasi klinis pada balita, sensitivitas, dan spesifisitas tetap harus dinilai melalui Gate C prospektif dengan hasil klinis independen.

4.11 Kontrol positif dewasa dan kesiapan

Kontrol positif menguji apakah rantai kamera-ke-angka merespons ketika orang dewasa sengaja memproduksi pola yang dicari. Dua belas orang dewasa memberi persetujuan dan menghasilkan 23 sesi pada tiga perangkat; 15 sesi lulus mutu. Denominator per kondisi adalah 9 dari 11 sesi menonton biasa dan 6 dari 12 sesi pola diproduksi yang dapat dipakai. Dalam mode demonstrasi, aturan menyala pada 0 dari 9 sesi biasa dan 4 dari 6 sesi pola diproduksi. Mode ini mengunci `emitsReferral` pada `false`. Tiga sinyal terpisah tanpa tumpang tindih, tetapi AUC 1,00 hanya menyatakan tidak ada pasangan yang terurut salah; margin terdekat dan denominator lengkap lebih informatif. Hasil ini adalah manipulation check dan responsivitas end-to-end, bukan sensitivitas, spesifisitas, ASD, atau status klinis peserta.

Matriks kesiapan yang dihasilkan bersama artefak publik menempatkan rantai pengukuran di perangkat sebagai siap untuk demonstrasi rekayasa dan respons dewasa sebagai telah ditunjukkan. Rujukan otomatis balita ditahan. Keterpakaian kader dan validitas balita Indonesia belum diuji. Validasi prospektif memerlukan mitra yang mampu menjalankan kaji etik, izin orang tua, acuan klinis buta, linkage privat, rekrutmen, analisis fairness dan kegagalan, serta validasi prospektif sebelum pemilihan titik operasi.

4.12 Penjaga out-of-distribution: dua arah, dan lintas runtime

Penjaga yang hanya pernah menolak tidak dapat dibedakan dari penolakan yang dipasang tetap. Karena itu penjaga dijalankan pada dua populasi. Pada 547 vektor fitur domain sumber Carette — kohort yang membangun referensinya — penjaga menerima 544, dengan jarak Mahalanobis median 10,8. Referensinya dikalibrasi pada persentil 99,5 sehingga tingkat penerimaan ini adalah pemeriksaan kewarasan, bukan uji generalisasi, dan disebut demikian. Pada 23 sesi kontrol positif yang berjalan di atas stimulus yang dikirim, penjaga menerima 1 sesi, dengan jarak Mahalanobis median 199,2 dan jarak robust maksimum median 14,0. Fitur yang paling sering ditandai adalah `ink_frac` pada 22 sesi, diikuti `n_active_cells` dan `centroid_y`. Ketiganya adalah fitur tata letak yang mengkodekan di mana isi stimulus studi asal duduk di layar, sehingga penolakannya konsisten dengan alasan yang dinyatakan di muka: batas keputusannya tidak berpindah ke stimulus yang berbeda.

Keputusan tersebut dibuat TypeScript di dalam peramban pada saat sesi berjalan. Seluruh 23 keputusan dihitung ulang oleh Python dari nilai fitur yang tersimpan di log audit dan menghasilkan verdict, jarak robust maksimum, serta jarak Mahalanobis yang sama dalam toleransi 10^{-6} . Artefaknya `research/hasil/ood_dua_arah.json`.

4.13 Bobot antar indeks pada data anak terbit: audit yang menolak

Lapis kedua model rujukan hendak memasang bobot relatif antar indeks pada anak berlabel yang datanya sudah diterbitkan peneliti lain, sehingga tidak ada balita yang perlu direkam. Sumber yang dipakai adalah Cilia dkk. 2022 (CC BY 4.0): 59 partisipan usia 3–12 tahun, eye-tracker 60 Hz, 2,25 juta baris koordinat mentah. Indeks dihitung di ruang perilaku dan bukan di ruang piksel, karena

fitur piksel mengkodekan tata letak stimulus dan tidak berpindah. Tiga indeks dapat direkonstruksi: perolehan lateral mengikuti isyarat, sebaran tatapan pada blok netral, dan proporsi dwell sosial. Respons nama tidak memiliki padanan karena protokol Cilia tidak memanggil nama anak.

Empat audit ditetapkan sebelum fitting dijalankan, beserta kriteria penolakannya. Dua di antaranya gagal. Pertama, selang kepercayaan bobot melewati nol untuk perolehan lateral dan dwell sosial. Kedua, dan lebih menentukan, alas shortcut tingkat sesi — jumlah sampel, rasio pelacakan, fraksi fiksasi, fraksi kedip, dan jumlah percobaan yang terbaca, tanpa satu pun fitur perilaku — mencapai AUC out-of-fold 0,905, sementara model indeks perilaku hanya 0,784. Prediktor tunggal terkuat pada dataset ini adalah rasio pelacakan (AUC 0,853), diikuti fraksi kedip (0,847) dan fraksi fiksasi (0,826); perolehan lateral mengikuti isyarat berada pada 0,504, yaitu kebetulan. Median jumlah percobaan yang terbaca adalah 13 untuk kelompok ASD dan 20 untuk kelompok TD.

Konsekuensinya bukan sekadar bahwa bobot ditolak. Pada dataset ini, seberapa baik alat merekam seorang anak lebih memprediksi labelnya daripada apa yang ditatap anak itu. Proksi cakupan scanpath — padanan langsung fitur `ink_frac` yang dibaca 13 fitur geometri maupun CNN scanpath — berkorelasi $r = 0,83$ dengan jumlah sampel dan hanya $r = 0,18$ dengan rasio pelacakan, sehingga ia terutama mengukur berapa banyak data yang sempit terkumpul. Setiap klasifikator pada dataset ini yang tidak menjalankan alas semacam ini berisiko melaporkan performa yang sebagian bersumber dari perbedaan pengumpulan data antar kelompok. Bobot tidak dipromosikan, Lapis 1 dikirim sendiri, dan penolakannya diterbitkan sebagai hasil di `research/hasil/model_rujukan.json`.

Menolak dataset pihak lain karena confound tanpa memeriksa confound yang sama pada data sendiri bukan kekakuan, jadi alas yang identik dijalankan pada kontrol positif. Tujuh ukuran mutu tingkat sesi — laju wajah terbaca, dropout tatapan, galat kalibrasi, pencahayaan, jumlah sampel, frame yang dicoba, dan frame yang ditolak karena pose — menghasilkan AUC out-of-fold 0,537 pada 15 sesi yang dipakai, dengan $p = 0,26$ pada permutasi dalam-perangkat 5.000 replikasi. Mutu rekaman tidak memisahkan kedua kondisi di atas kebetulan; yang memisahkannya adalah sinyal perilaku. Uji ini lebih lemah daripada padanannya pada data Cilia dan batasnya dinyatakan: n kecil, dan identitas peserta tidak terekam pada 22 dari 24 log sehingga perangkat menjadi satu-satunya pengelompokan yang tersedia. Artefaknya `research/hasil/audit_shortcut_sendiri.json`.

4.14 Wawancara praktisi

Satu wawancara dengan seorang guru sekolah luar biasa di Jambi menjadi riset primer pertama proyek ini. Ia memvalidasi masalahnya, bukan instrumennya: narasumber tidak melihat, menjalankan, atau menilai aplikasi. Dengan $n = 1$ dan jawaban berbasis ingatan, tidak ada angka pada makalah ini yang digeser olehnya.

Tiga hal yang dilaporkan relevan terhadap keputusan desain yang sudah diambil. Pertama, kapasitas rujukan: ditanya apakah layanan sanggup menampung tiga kali lipat anak yang disarankan diperiksa lanjut, jawabannya adalah tidak, dengan alasan tenaga dan jadwal yang tersedia, sementara keluarga sudah menunggu beberapa minggu sampai beberapa bulan untuk layanan tertentu. Argumen memilih titik kerja bersensitivitas rendah selama ini bersandar sepenuhnya pada simulasi; kini ia memiliki satu observasi lapangan di sampingnya. Titik kerja yang dikirim menghasilkan beban rujukan paling rendah di antara seluruh lengan, sedangkan lengan bersensitivitas 0,92 menghasilkan 38,3 kali beban itu. Kedua, risiko rasa aman palsu: hasil di bawah ambang diperkirakan akan dibaca orang tua sebagai anaknya pasti normal, yang merupakan pembenaran kedua untuk `reassures: false` dari arah selain NPV 65 persen. Ketiga, sebuah kekurangan produk: setelah hasil keluar, harus jelas siapa yang menjelaskan dan mendampingi orang tua. Laporan sebelumnya menyebut tujuan tanpa menyebut pendamping, dan bagian langkah berikutnya diubah karenanya.

4.15 Ringkasan capaian validasi

Tabel 10 pada Lampiran E merangkum posisi tiap tingkat validasi terhadap lingkup makalah ini. Tiga tingkat sudah tuntas. Validasi algoritmiknya menjawab seluruh endpoint yang kami pra-tetapkan dari data uji tertahan. Gate A lulus pada 100 sesi dewasa lintas tiga perangkat, dua kondisi pencahayaan, serta peserta dengan dan tanpa kacamata. Gate B lulus pada 30 perbandingan browser simultan terhadap WebGazer.js, dengan seluruh lima kriteria agreement terpenuhi.

Dua tingkat sisanya tetap terbuka. Untuk Gate C, targetnya kami ambil dari literatur alih-alih dari data kami sendiri: sensitivitas 87,8 persen dan spesifisitas 80,8 persen yang dicapai SenseToKnow pada kamera depan tablet untuk anak 17-36 bulan [18]. Angka sekunder dari dataset Carette sengaja tidak diwariskan sebagai kandidat titik kerja, sebab populasi maupun instrumennya berbeda dan CNN-nya tidak dapat dijalankan pada perangkat sasaran. Cabang prospektifnya tetap terbuka dengan kohort balita nol. Untuk Gate D, protokol ramah anak, jarak layar sekitar 60 cm, posisi duduk fleksibel, kalibrasi lima titik, dan stimulus naturalistik sudah dipakai pada studi eye-tracking anak, tetapi pengujian lapangan tetap terbuka dengan nol Posyandu, nol kader, dan nol sesi anak. Bukti sekunder ini tidak setara dengan validasi klinis atau operasional Neurogaze.

5 Nilai Bisnis dan Jalur Adopsi

5.1 Peran, biaya, dan titik masuk layanan

Tiga peran sering tertukar, jadi kami pisahkan sebagai hipotesis implementasi. Penerima manfaat yang dituju adalah anak 16–30 bulan beserta pengasuhnya. Operator yang diusulkan adalah kader di bawah supervisi Puskesmas, tetapi belum ada kader yang menguji aplikasi. Skema pembiayaan dan penerimaan laporan juga belum diuji dengan Dinas Kesehatan atau praktisi.

PWA statis membuat biaya distribusi perangkat lunak mendekati nol dan tidak memerlukan lisensi per kursi. Biaya operasi belum diukur: waktu kader, pelatihan, dukungan, pencetakan, dudukan, pengulangan, pemeliharaan, penggantian tablet, dan tindak lanjut klinis semuanya tetap ada. Karena itu simulasi biaya per sesi maupun per kasus di Lampiran hanya skenario bersyarat apabila protokol penuh dan titik operasi terbit berhasil direplikasi, bukan performa atau biaya NeuroGaze yang diamati. Sebagai pembanding, EarliPoint, instrumen tatapan berizin FDA untuk rentang usia yang sama, memerlukan eye-tracker khusus di fasilitas klinis dengan biaya pemeriksaan 599 dolar Amerika [17]. Neurogaze tidak bersaing dengan ketepatan instrumen itu; pesaingnya ketiadaan pemeriksaan sama sekali.

Titik masuk yang diusulkan adalah alur Posyandu. Baterai pengukuran berlangsung 67 detik; izin, penempatan, kalibrasi, kemungkinan pengulangan, dan penjelasan menambah waktu kunjungan. Durasi total dan penerimaannya belum diukur pada kader atau balita.

5.2 Skalabilitas dan jalur adopsi bertahap

Skala kabupaten belum dapat diproyeksikan dari data proyek ini. Kapasitas asesmen lanjutan, attrition, waktu kader, dan pengulangan harus diukur sebelum jumlah sesi atau biaya dapat dipakai untuk keputusan program.

Perluasannya bertahap, dengan gerbang validasi sebagai syarat lolos tiap tahap, bukan target komersial. Tahap pertama kemitraan dengan rumah sakit, klinik tumbuh kembang, dan pusat terapi, yang menyelesaikan dua masalah sekaligus: mitra klinis menyediakan kohort berlabel, klinisi yang dibuktikan untuk menetapkan acuan, serta tata kelola kaji etik untuk Gate C. Kemitraan ini tidak dapat direduksi menjadi persetujuan administratif. Tahap kedua adopsi oleh Dinas Kesehatan kabupaten setelah Gate D menunjukkan produk dapat dijalankan kader tanpa mengganggu layanan. Tahap ketiga perluasan lintas wilayah dengan kalibrasi ulang terhadap norma setempat, karena norma pola tatapan tidak otomatis berpindah antar populasi.

6 Diskusi

6.1 Cakupan kesimpulan yang ditopang hasil

Validasi yang kami tuntaskan menopang lima kesimpulan. Geometri scanpath memuat sinyal berukuran efek besar yang bertahan pada anak yang tidak pernah dilihat model (AUC 0,8228), dan bertahan lebih baik daripada fitur kinematik pada kondisi yang menyerupai kamera konsumen. Protokol splitnya terverifikasi tahan bocor lewat kontrol negatif. Seluruh rantai dari kalibrasi sampai laporan berjalan luring dengan paritas numerik 10^{-12} terhadap implementasi riset, sehingga angka di notebook dan produk yang dipakai kader dijamin identik oleh uji otomatis. Kamera tablet bisa cukup presisi untuk mengukur arah pandangan pada kondisi lapangan yang wajar, dengan galat

median $2,2^\circ$ dan penyelesaian sesi 94 persen pada 100 sesi (Bagian 4.9). Aliran gaze Neurogaze juga memenuhi seluruh kriteria agreement terhadap WebGazer.js, dengan galat median ternormalisasi 0,040997 dan agreement AOI 99,7118 persen pada 27 dari 30 pasangan yang siap (Bagian 4.10).

Batas kelimanya sama dan perlu dinyatakan tegas: Gate A membuktikan kelayakan teknis dan Gate B membuktikan agreement terhadap WebGazer.js, tetapi tidak satu pun membuktikan akurasi diagnosis ASD. Klaim klinis tetap menunggu kohort balita dengan hasil klinis independen yang dinilai secara buta.

6.2 Alasan model ber-AUC tertinggi tidak dipakai di produk

CNN scanpath unggul 0,059 AUC dan titik kerjanya jauh lebih seimbang, tetapi tidak masuk produk. Penghalang pertamanya kontrak input. Model yang di-deploy harus memakan aliran (x, y, t) dari kamera 30 fps di dalam browser, sedangkan citra scanpath Carette adalah raster yang sudah dirender dengan kanal warna kecepatan, akselerasi, dan jerk dari sinyal 250 Hz. Melatih CNN pada citra itu lalu memberinya raster dari kamera tablet berarti menguji model pada distribusi yang berbeda dari distribusi pelatihannya, dan kenaikan 0,059 pada dataset sumber tidak menjamin apa pun setelah perpindahan itu.

Penghalang kedua bersifat operasional. Regresi logistik 13 fitur berjalan pada median 4,93 ms, dapat diekspor sebagai `model.json` berisi koefisien dan kalibrator yang terbaca manusia, dan kontribusi tiap fiturnya dapat diaudit. Yang menjalankan produk ini kader, dengan latar pelatihan berbeda dari klinisi, dan di konteks itu kemampuan menjelaskan alasan seorang anak disarankan dirujuk bernilai lebih besar daripada 0,059 AUC pada dataset yang populasinya berbeda dari sasaran. Angka CNN tetap kami laporkan karena menjawab pertanyaan lain yang sah, yaitu berapa banyak sinyal yang ada di representasi ini bila kapasitas model tidak dibatasi.

6.3 Menolak dataset yang menguntungkan

CNN yang kami latih pada dataset wajah statis sebagai audit metodologis mencapai AUC uji 0,9324, angka tertinggi di proyek ini. Kami tidak memasukkannya sebagai hasil, dengan tiga alasan yang berdiri sendiri-sendiri. Inferensi karakteristik neurologis dari morfologi wajah statis memikul beban sejarah fisiognomi. Dataset itu tidak punya persetujuan subjek terdokumentasi untuk anak-anak yang dapat diidentifikasi. Dan tanpa identitas partisipan, tidak ada evaluasi yang dapat membuktikan model tidak sekadar menghafal orang; alasan ketiga ini teknis, jadi menambah izin sekalipun tidak akan memperbaikinya.

Uji shortcut menunjukkan performa itu tidak seluruhnya artefak teknis, tetapi juga tidak bersih: properti berkas saja mencapai AUC 0,6757 dan penambahan statistik piksel tingkat rendah menaikkan ke 0,7515. Sisa jaraknya tidak dijelaskan, dan tanpa provenance kami tidak punya cara mengetahui asalnya. Keputusan menolak diambil di tingkat tata kelola, bukan tingkat metrik; Lampiran D memuat audit lengkapnya.

6.4 Prasyarat kelembagaan untuk tahap berikutnya

Validasi algoritmik, Gate A, dan Gate B dapat kami tuntaskan sendiri karena ketiganya tidak menuntut peserta anak dengan diagnosis. Gate C prospektif dan Gate D lapangan berbeda: keduanya terhalang prasyarat kelembagaan di luar jangkauan teknis kami, dan kami mengujinya langsung. Untuk memperoleh data sesi dari anak dengan diagnosis, kami menghubungi lima lembaga terapi dan layanan autisme di Surabaya dan sekitarnya. Tidak satu pun membuka akses, dan itu keputusan yang benar dari pihak mereka: lembaga terapi memikul kewajiban perlindungan terhadap anak dan keluarga, dan permintaan pengumpulan data dari pihak tanpa tinjauan etik formal, sponsor institusional, maupun rekam jejak klinis memang seharusnya ditolak.

Jalur data klinis, dengan kata lain, hanya terbuka lewat kemitraan institusional berizin etik, jadi prioritas pertama pada Bagian 6.7 kemitraan klinis, bukan pekerjaan teknis tambahan.

6.5 Risiko dan mitigasi

Risiko pelabelan ditekan dengan membatasi keluaran pada rekomendasi rujukan, menampilkan ketidakpastian, dan mensyaratkan persetujuan yang dapat ditarik. Risiko privasi ditekan dengan memp-

roses seluruh video di perangkat dan hanya mempertahankan fitur serta skor pseudonim. Risiko klaim berlebih ditekan lewat struktur aplikasinya: sesi kamera melaporkan pengukuran Lapis A dan Lapis B beserta provenance tiap indeks dan tidak pernah mengeluarkan skor gabungan maupun probabilitas ASD, keluaran regresi logistik dikurung di panel riset berpenapis out-of-distribution, dan halaman bukti publik menolak menampilkan metrik tanpa berkas comparison dan ambang pra-registrasi. Lapis A adalah satu-satunya kandidat rujukan dengan titik operasi terbit, tetapi klip 16,75 detik menahan keluarannya. Tabel 2 hanya mensimulasikan beban jika titik operasi protokol penuh kelak direplikasi.

Dua risiko masih terbuka. Performa per subkelompok memerlukan demografi yang tidak disediakan dataset anchor, dan perilaku model terhadap anak dengan hambatan perkembangan non-autisme hanya terukur lewat kontrol negatif sulit dari kohort prospektif. Keduanya masuk sebagai endpoint wajib pada Lampiran A.

6.6 Catatan tata kelola: keadilan, pra-registrasi subgrup, dan konteks Indonesia

Tiga hal perlu dinyatakan sebelum sistem ini dibawa ke lapangan, dan kami menyatakannya di muka karena ketiganya lebih mudah diabaikan daripada dibantah.

Pertama, preseden yang kami pakai punya kesenjangan performa lintas kelompok. Pada studi SenseToKnow, spesifisitasnya 53,6 persen pada anak kulit hitam berbanding 82,7 persen pada anak kulit putih [18]. Kesenjangan sebesar itu pada instrumen yang menjadi preseden Lapis B berarti risiko rujukan berlebih tidak terdistribusi rata, dan pada konteks Indonesia sumber variasinya bisa berbeda lagi: warna kulit, bentuk kelopak, dan pemakaian kerudung yang menutupi tepi wajah semuanya menyentuh langkah deteksi landmark. GeoPref sendiri dilaporkan setara lintas ras pada studi aslinya, tetapi kesetaraan pada satu populasi bukan jaminan pada populasi lain.

Kedua, analisis subgrup harus dipra-registrasi, bukan dicari setelah datanya terlihat. Kami memasukkan performa per subkelompok sebagai endpoint wajib Gate C pada Lampiran A, dengan stratifikasi yang ditetapkan lebih dulu, sebab subgrup yang dipilih setelah melihat hasil selalu dapat dibuat tampak baik. Ini juga satu-satunya cara menutup batasan yang diwarisi dari data pengembangan: dataset anchor tidak menyediakan demografi sama sekali, sehingga tidak ada analisis keadilan yang dapat dilakukan pada hasil di Bagian 4.

Ketiga, tidak satu pun instrumen yang dipakai di sini divalidasi di Indonesia. Ambang GeoPref berasal dari kohort Amerika Serikat, keluarga indeks Lapis B dari layanan primer Amerika Serikat, dan referensi Gate B dari 16 laboratorium yang seluruhnya di luar Indonesia. Yang berpindah lintas populasi bukan hanya distribusi perilakunya, tetapi juga jalur layanan sesudah rujukan: sebuah alat *rule-in* hanya bernilai bila ada kapasitas asesmen yang menerima rujukannya. Karena itu Gate D mengukur beban layanan, bukan hanya kegunaan antarmuka. Dan perlu diulang sekali lagi di bagian ini, karena inilah batasan yang paling mudah lupa disebut: belum ada satu pun balita dalam bukti mana pun di makalah ini.

6.7 Pengembangan lanjutan

Dengan Gate A dan Gate B tertutup, sisa pekerjaannya tidak lagi bersifat teknis melainkan kelembagaan, dan urutan di bawah mengikuti prasyarat itu. Pertama, kemitraan formal dengan rumah sakit atau klinik tumbuh kembang berkomite etik, satu-satunya kunci yang membuka Gate C prospektif. Kedua, kohort prospektif Gate C pada balita 16-30 bulan dengan acuan klinis buta dan kontrol negatif sulit, yaitu anak dengan hambatan perkembangan non-autisme; hanya di tahap inilah ambang klinis boleh dipilih. Sasarannya sensitivitas 87,8 persen dan spesifisitas 80,8 persen, yaitu performa terbit SenseToKnow pada kelas perangkat yang sama [18], dan endpoint keadilan pada Bagian 6.6 masuk ke protokolnya sejak awal. Ketiga, Gate D di Posyandu dengan target 5 Posyandu, 20 kader, 200 sesi anak, dan tiga tipe tablet Android, untuk mengukur waktu layanan, keberhasilan sesi pertama, pemahaman laporan, dan penerimaan orang tua. Keempat, perluasan matriks Gate A dan Gate B ke lebih banyak tipe perangkat dan kondisi klinis, karena kedua gerbang itu lulus pada sampel yang masih kecil. Cabang vokalisasi dan gerak kepala diuji bersama kohort prospektif sebagai hipotesis.

7 Kesimpulan

Neurogaze saat ini adalah demonstrasi rekayasa dengan rantai pengukuran, penolakan, dan pelaporan yang dapat diaudit. Model Carette memberi bukti konsep participant-grouped pada domain sumber anak usia sekolah Prancis 250 Hz; ia tidak memiliki uji eksternal, sengaja ditolak penjaga OOD pada sesi sekarang, dan tidak pernah menentukan keputusan. Gate A mencakup 100 sesi berulang dari 25 dewasa dengan 94 lulus mutu. Gate B mencakup 30 perbandingan simultan terhadap implementasi referensi WebGazer.js, dengan 27 siap dan tiga ditahan; ia mengukur agreement perangkat lunak, bukan ground truth. Kontrol positif dewasa menunjukkan respons kamera-ke-angka pada 15 dari 23 sesi yang lulus mutu, dengan aturan demo 0/9 pada kondisi biasa dan 4/6 pada pola diproduksi. Rujukan otomatis balita ditahan karena klip 16,75 detik tidak mereplikasi protokol penuh titik operasi 69 persen.

Belum ada balita, uji kader, validasi Indonesia, wawancara praktisi, atau linkage klinis. Tahap berikutnya memerlukan mitra yang mampu menjalankan kaji etik, izin orang tua, acuan klinis buta, linkage privat, rekrutmen, analisis fairness dan kegagalan, serta validasi prospektif sebelum titik operasi dipilih. Tidak satu pun hasil makalah ini merupakan bukti akurasi skrining ASD pada NeuroGaze.

Ketersediaan artefak

Kode dan notebook ada di https://github.com/raphaeladikara/Dataton_Project_RizZZ, dan aplikasinya dapat dicoba tanpa pemasangan di <https://dataton-project-rizZZ.vercel.app>. Bobot model gaze yang terlatih tersedia di <https://huggingface.co/raphaeladikara/neurogaze-gaze-lr-v1>.

Pustaka

- [1] G. Dawson, S. Rogers, J. Munson, M. Smith, J. Winter, J. Greenson, A. Donaldson, dan J. Varley. Randomized controlled trial of an intervention for toddlers with autism: the Early Start Denver Model. *Pediatrics*, 125(1):e17-e23, 2010.
- [2] M. van 't Hof, C. Tisseur, I. van Berckelaer-Onnes, A. van Nieuwenhuyzen, A. M. Daniels, M. Deen, H. W. Hoek, dan W. A. Ester. Age at autism spectrum disorder diagnosis: a systematic review and meta-analysis from 2012 to 2019. *Autism*, 25(4):862-873, 2021.
- [3] A. L. Harper, D. E. Sarver, dan K. F. Sly. Validation of the Modified Checklist for Autism in Toddlers (M-CHAT): a replication study of diagnostic accuracy. *Journal of Autism and Developmental Disorders*, 2026. doi:10.1007/s10803-026-07330-3.
- [4] R. Sturmer, B. Howard, P. Bergmann, D. Morrel, L. Andon, C. Marks, P. Rao, dan M. Landa. Autism screening with online decision support by primary care pediatricians aided by M-CHAT/F. *Pediatrics*, 138(3):e20153036, 2016.
- [5] Fathmawati, L. Andari, J. Saimin, D. F. Damayanti, Z. Akhmadi, dan E. D. Septiawan. Distribution of autistic children in Pontianak, West Kalimantan Province, Indonesia. *Malaysian Journal of Public Health Medicine*, 23(2):124-130, 2023. doi:10.37268/mjphm/vol.23/no.2/art.1826.
- [6] C. J. Aditya, J. K. Dahliana, A. D. Widodo, dan R. Sekartini. Autism spectrum disorder screening in children aged 16-30 months using the Modified Checklist for Autism in Toddlers-Revised (M-CHAT-R). *Paediatrica Indonesiana*, 61(5):247-252, 2021. doi:10.14238/pi61.5.2021.247-52.
- [7] Kementerian Koordinator Bidang Pembangunan Manusia dan Kebudayaan RI. Posyandu miliki peran penting ciptakan generasi emas Indonesia, 2023.
- [8] A. Mardhika, J. Susanto, E. Qurniyawati, dan A. P. M. Tyas. Empowerment of healthcare cadres on stimulation of early detection and intervention of growth and development. *Abdimas Unwahas*, 7(2), 2022. doi:10.26905/abdimas.v7i2.6909.
- [9] W. Jones dan A. Klin. Attention to eyes is present but in decline in 2-6-month-old infants later diagnosed with autism. *Nature*, 504(7480):427-431, 2013.
- [10] K. Pierce, D. Conant, R. Hazin, R. Stoner, dan J. Desmond. Preference for geometric patterns early in life as a risk factor for autism. *Archives of General Psychiatry*, 68(1):101-109, 2011.
- [11] A. Moore, M. Wozniak, A. Yousef, C. C. Barnes, D. Cha, E. Courchesne, dan K. Pierce. The geometric preference subtype in ASD: identifying a consistent, early-emerging phenomenon through eye tracking. *Molecular Autism*, 9:19, 2018. doi:10.1186/s13229-018-0202-z.
- [12] T. H. Wen, A. Cheng, C. Andreason, J. Zahir, Y. Xiao, R. Xu, B. Bao, E. Courchesne, C. C. Barnes, S. J. Arias, dan K. Pierce. Large scale validation of an early-age eye-tracking biomarker of an autism spectrum disorder subtype. *Scientific Reports*, 12(1):4253, 2022. doi:10.1038/s41598-022-08102-6.
- [13] L. Billeci, S. Narzisi, A. Tonacci, dkk. Disentangling the initiation from the response in joint attention: an eye-tracking study in toddlers with autism spectrum disorders. *Frontiers in Psychology*, 10:2187, 2019. doi:10.3389/fpsyg.2019.02187.
- [14] T. Farroni, S. Massaccesi, D. Pividori, dan M. H. Johnson. Gaze following in newborns. *Infancy*, 5(1):39-60, 2004.
- [15] G. Gredebäck dkk. Schematic eye-gaze cues influence infants' object encoding dependent on their contrast polarity. *Scientific Reports*, 7:9506, 2017. doi:10.1038/s41598-017-10108-4.
- [16] U.S. Food and Drug Administration. EarliPoint System, 510(k) K213882, 2022; EarliPoint, 510(k) K230337, 2023.
- [17] EarliPoint Health. Frequently asked questions. Diakses 2026.
- [18] S. Perochon, J. M. Di Martino, K. L. H. Carpenter, S. Compton, N. Davis, B. Eichner, S. Espinosa, L. Franz, P. R. Krishnappa Babu, G. Sapiro, dan G. Dawson. Early detection of autism using digital behavioral phenotyping. *Nature Medicine*, 29:2489-2497, 2023. doi:10.1038/s41591-023-02574-3.
- [19] A. Steffan, L. Zimmer, N. Arias-Trejo, M. Bohn, R. Dal Ben, dkk. Validation of an open source, remote web-based eye-tracking method (WebGazer) for research in early childhood. *Infancy*, 29(1):31-55, 2024. doi:10.1111/inf.12564.

- [20] A. Papoutsaki, P. Sangkloy, J. Laskey, N. Daskalova, J. Huang, dan J. Hays. WebGazer: scalable webcam eye tracking using user interactions. Dalam *Proceedings of the 25th International Joint Conference on Artificial Intelligence (IJCAI)*, halaman 3839-3845, 2016.
- [21] R. Carette, M. Elbattah, F. Cilia, G. Dequen, J.-L. Guérin, dan J. Bosche. Learning to predict autism spectrum disorder based on the visual patterns of eye-tracking scanpaths. Dalam *Proceedings of BIOSTEC 2019 (HEALTHINF)*, halaman 103-112, 2019.
- [22] M. Tan dan Q. V. Le. EfficientNet: rethinking model scaling for convolutional neural networks. Dalam *Proceedings of the 36th International Conference on Machine Learning*, halaman 6105-6114, 2019.


Lampiran A. Kriteria validasi pra-tetap

Bagian pertama tabel memuat endpoint validasi algoritmik yang menjadi lingkup makalah ini; seluruhnya ditetapkan sebelum eksperimen dijalankan dan seluruhnya terjawab dari data uji tertahan. Bagian kedua memuat kriteria Gate A dan Gate B, yang juga ditetapkan lebih dulu dan kini seluruhnya terjawab dari data pengujian instrumen. Bagian ketiga memuat kriteria Gate C dan Gate D yang belum terjawab, dipublikasikan lebih dulu justru agar sasarannya tidak dapat digeser setelah datanya terlihat. Kegagalan pada satu baris menghentikan konfigurasi perangkat atau stimulus yang diuji; nilai di zona tengah mewajibkan satu putaran perbaikan terarah lalu pengukuran ulang pada sampel baru, bukan penyetelan ulang model terhadap data yang sama.

Tingkat	Endpoint	Ambang lulus	Hasil
<i>Validasi algoritmik: lingkup makalah ini</i>			
Algoritmik	AUC tingkat anak, uji tertahan	$> 0,75$	0,8228 ✓
Algoritmik	irisan anak antar split	$= 0$	0 ✓
Algoritmik	AUC pada proxy tablet gabungan	$> 0,60$	0,6827 ✓
Algoritmik	set fitur dapat dihitung 30 fps	wajib	13 fitur ✓
Algoritmik	paritas Python-TypeScript	$< 10^{-9}$	10^{-12} ✓
Algoritmik	tata kelola dataset terdokumentasi	wajib	audit lengkap ✓
<i>Gate A dan B: dipra-registrasi, sudah terjawab</i>			
A	galat median kalibrasi	$\leq 3^\circ$	2,2° ✓
A	frame wajah/iris valid	$\geq 85\%$	96,4% ✓
A	session completion	$\geq 90\%$	94% ✓
A	skor dari sesi invalid	$= 0$	0 ✓
A	P90 ekstraksi	< 100 ms	7,67 ms ✓
B	jumlah pasangan	≥ 30	30 ✓
B	valid pair rate	$\geq 90\%$	90% ✓
B	galat median ternormalisasi	$\leq 0,05$	0,040997 ✓
B	AOI agreement rata-rata	$\geq 95\%$	99,7118% ✓
B	agreement AOI utama	$\geq 95\%$	100% ✓
<i>Gate C dan D: dipra-registrasi, belum terjawab</i>			
C	AUC tingkat anak balita	ditetapkan bersama klinisi	kohort prospektif
C	kontrol negatif sulit	wajib ada	kohort prospektif
C	sesi cakupan rendah ditahan	wajib	kohort prospektif
D	median waktu layanan	≤ 5 menit	studi lapangan
D	kapasitas per perangkat	≥ 10 anak/jam	studi lapangan

Lampiran B. Tiga status laporan produk

(a) Disarankan dirujuk



(b) Pantau sesuai SDIDTK



(c) Skor tidak dikeluarkan



Gambar 3: Tiga status laporan yang dapat diuji melalui replay deterministik bawaan. (a) rekomendasi rujukan; (b) pantau sesuai alur SDIDTK; (c) keputusan ditahan karena kualitas pengukuran tidak memadai, disertai alasan yang dapat ditindaklanjuti kader. Ketiganya menampilkan pernyataan bukan diagnosis serta versi aplikasi, model, dan stimulus.

Lampiran C. Rancangan data prospektif dan target operasional

Data prospektif (rancangan tahap deployment). Rancangan kohort berpasangan di Posyandu, dengan seluruh modalitas direkam dari anak dan sesi yang sama, acuan berupa asesmen perkembangan

terstandar dan diagnosis konsensus oleh klinisi yang dibutakan terhadap keluaran Neurogaze, serta satu lokasi yang disisihkan sebagai validasi eksternal. Kohort ini wajib memuat anak dengan hambatan perkembangan non-autisme sebagai kontrol negatif sulit; tanpa mereka spesifisitas hanya terukur terhadap anak tipikal. Bagian 6.4 menjelaskan prasyarat kelembagaan yang membuka jalur ini.

Seluruh nilai berikut adalah target penerimaan, bukan hasil pengukuran: alur inti berjalan tanpa jaringan setelah aset terpasang; perangkat Android kelas menengah dengan kamera depan minimal 5 MP pada 30 fps dan RAM minimal 4 GB; median waktu layanan 5 menit dengan P90 7 menit; kapasitas minimal 10 anak per jam per perangkat; quality gate mensyaratkan minimal 85 persen frame dengan wajah dan iris terdeteksi; presisi gaze $\leq 3^\circ$ lulus, $3-5^\circ$ revisi, $> 5^\circ$ gagal; tidak ada unggahan media mentah pada alur MVP; setiap hasil menyimpan versi aplikasi, model, stimulus, dan aturan.

Lampiran D. Audit dataset wajah dan keputusan karantina

Lampiran ini melaporkan audit penuh atas dataset citra wajah statis publik yang kami tolak, beserta angka-angka yang menjadi dasar penolakan. Tidak ada satu pun bobot atau fitur dari eksperimen di lampiran ini yang masuk ke Neurogaze.

Integritas teknis: lulus. Seluruh 2.940 JPEG dapat dibaca, tidak ada berkas rusak, tidak ada duplikat exact, dan hanya terdapat 10 pasangan near-duplicate pada pHash ≤ 4 yang tidak satu pun melintasi label. Klasifikasi seimbang sempurna pada 1.470 citra per kelas. Dataset ini, dengan kata lain, tidak ditolak karena kotor.

Tata kelola: enam dari enam gagal. Tabel 3 merangkumnya. Perlu dibedakan lisensi platform dari persetujuan subjek: keduanya bukan hal yang sama, dan yang kedua tidak dapat digantikan oleh yang pertama. Ketiadaan identitas partisipan berdiri sendiri sebagai penggugur, karena tanpanya tidak ada cara membuktikan foto orang yang sama tidak menyeberang split, sehingga estimasi performa apa pun tidak dapat ditafsirkan.

Tabel 3: Metadata tata kelola yang diperiksa. Sumber: `research/hasil/audit_wajah.json`.

Metadata	Status	Akibat bila tidak ada
Sumber (provenance)	tidak ada	rantai asal data tidak dapat dilacak
Lisensi tertulis	tidak ada	dasar hukum pemakaian tidak jelas
Persetujuan subjek	tidak ada	anak dapat diidentifikasi tanpa izin
Demografi	tidak ada	audit bias subkelompok tidak mungkin
Definisi label klinis	tidak ada	arti label <i>Autistic</i> tidak diketahui
Identitas partisipan	tidak ada	evaluasi tidak dapat ditafsirkan

Dua uji shortcut. Kami menguji apakah label dapat ditebak tanpa memodelkan wajah. Dengan lima properti berkas saja (lebar, tinggi, ukuran, rasio aspek, bytes per piksel), regresi logistik mencapai AUC 0,4778 dan gradient boosting 0,6757. Dengan sepuluh fitur yang menambahkan statistik piksel tingkat rendah (rerata kanal RGB, simpangan baku kecerahan, kecerahan tepi, energi tepi), regresi logistik mencapai 0,7515 dengan permutation $p = 0,005$ atas 200 permutasi. Angka kedua konsisten dengan temuan bahwa dua puluh resolusi terbanyak seluruhnya berasal dari kelas *Non_Autistic*. Kami melaporkan keduanya karena keduanya relevan dan arahnya berbeda: ada shortcut koleksi yang nyata, tetapi besarnya tidak cukup menjelaskan performa CNN.

CNN audit. Di bawah *governance gate* yang harus di-override secara sadar, CNN EfficientNetB3 berpretrain ImageNet dilatih pada dataset ini. AUC uji mencapai 0,9324 (95% CI 0,9070-0,9537), dengan average precision 0,9266, akurasi seimbang 0,8425, MCC 0,6861, sensitivitas 0,8143, dan spesifisitas 0,8708 pada ambang 0,5436 yang dikunci dari validation. Split memakai grup near-duplicate dHash, yang menghilangkan kebocoran citra identik tetapi *tidak* membuat split aman terhadap identitas orang.

Penegakan keputusan di kode. Keputusan tidak berhenti sebagai pernyataan. Notebook memuat enam flag tata kelola yang seluruhnya *False* dan berhenti kecuali `OVERRIDE_QUARANTINE` dinyatakan sadar untuk keperluan audit. Ekspor artefak dijaga `ALLOW_MODEL_EXPORT = False`, sehingga sel ekspor tidak pernah berjalan dan tidak ada bobot yang tersimpan di repositori. Dataset diberi status `reject_for_asd_modeling_and_quarantine`, dan `audit_wajah.json` mencatat syarat peninjauan ulang: provenance, lisensi, persetujuan, demografi, dan definisi label terdokumentasi; identitas partisipan stabil yang memungkinkan evaluasi berkelompok; serta tinjauan

etik yang membenarkan pertanyaan riset yang relevan secara perilaku. Ketiganya harus dipenuhi bersama, bukan salah satu.

Batas penafsiran. Angka 0,9324 tidak boleh dibaca sebagai bukti bahwa autisme dapat dibaca dari morfologi wajah statis. Ia hanya membuktikan bahwa metrik yang terlihat meyakinkan dapat diproduksi dari data yang tidak boleh dipakai. Artefak auditnya tersimpan pada folder `audit_wajah` beserta notebooknya.

Lampiran E. Tabel pendukung dan rincian hasil

Tabel 4: Hasil model pada 547 scanpath dari 54 anak, seluruhnya dengan evaluasi dikelompokkan per anak. Baris terakhir dicantumkan sebagai pembandingan representasi dan tidak dipakai sebagai model produk.

Model	Representasi	AUC anak	95% CI	Status
Regresi logistik	13 fitur geometri	0,8228	0,6974-0,9290	dibekukan sebagai MVP
Regresi logistik	19 fitur penuh	0,8324	0,7069-0,9368	butuh eye-tracker 250 Hz
EfficientNetB0	citra scanpath	0,8819	0,7738-0,9681	tidak dijalankan di produk

Tabel 5: Gate A: hasil menurut kondisi pengujian, 100 sesi dari 25 peserta dewasa.

Kondisi	Sesi	Sesi berhasil	Galat median
Cahaya normal	50	49 (98%)	1,9°
Cahaya redup	25	22 (88%)	2,8°
Tanpa kacamata	70	68 (97%)	2,0°
Dengan kacamata	30	26 (87%)	2,9°
Seluruh sesi	100	94 (94%)	2,2°

Tabel 6: Gate B: distribusi AOI pada 27 pasangan siap.

Area perhatian	WebGazer	Neurogaze
Wajah	17,1628%	17,1374%
Target kiri	32,7535%	32,8137%
Target kanan	33,2116%	33,2336%
Latar	16,8720%	16,8152%

Tabel 7: Posisi Neurogaze terhadap alternatif yang tersedia. Kolom Neurogaze menyatakan status implementasi saat makalah ini ditulis, bukan target.

Dimensi	M-CHAT	EarliPoint	SenseToKnow	Neurogaze
Instrumen	ceklis orang tua	eye-tracker khusus	kamera tablet	kamera tablet
Lokasi	mana saja	fasilitas klinis	layanan primer	Posyandu
Operator	orang tua	tenaga terlatih	tenaga klinis	kader
Konektivitas	tidak perlu	fasilitas	daring	luring penuh
Biaya per pemeriksaan	mendekati nol	599 USD	tidak dipublikasi	belum diukur; distribusi perangkat lunak statis
Tahap validasi	klinis luas	izin FDA	prospektif 475 anak	demonstrasi rekayasa; klinis belum diuji
Menahan keputusan	tidak	tidak dipublikasi	tidak dipublikasi	ya, eksplisit

Rincian hasil sistem dan reproduktibilitas.

Implementasi PWA memuat Face Landmarker WASM lokal, kalibrasi, stimulus, ekstraksi fitur, inferensi, quality gate, laporan tiga status, dan replay deterministik. Paritas numerik antara implementasi

Tabel 8: Titik kerja tingkat anak pada data uji tertahan. Kolom terakhir adalah jumlah anak yang dirujuk per 100 anak yang diskriminasi, yaitu besaran yang langsung menentukan beban kapasitas rujukan.

Ambang	Sensitivitas	Spesifisitas	NPP	NPN	Dirujuk/100
0,2243 (target sens. 0,9)	0,885	0,179	0,500	0,625	85,2
0,3500	0,885	0,464	0,605	0,812	70,4
0,4000	0,846	0,607	0,667	0,810	61,1
0,4500	0,769	0,679	0,690	0,760	53,7
0,4985 (Youden)	0,731	0,821	0,760	0,793	46,3

Python (`research/features.py`) dan TypeScript (`app/src/scanpath/features.ts`) diuji terhadap fixture bersama dan lulus pada toleransi 10^{-12} , baik untuk nilai fitur maupun untuk probabilitas model. Rangkaian uji berjalan pada 16 dari 16 uji Python, 55 dari 55 uji TypeScript, dan 2 dari 2 kontrak build/offline. Uji browser nyata memuat PWA, mengaktifkan service worker, mematikan server, memuat ulang halaman, dan replay tetap berfungsi tanpa galat konsol.

Benchmark rantai raster → fitur → inferensi untuk 360 titik pada 250 iterasi memberi median 4,93 ms dan P90 7,67 ms pada desktop referensi (Intel Core Ultra 5 135H), yaitu margin sekitar tiga belas kali lipat terhadap ambang penerimaan 100 ms. Angka ini kami tandai sebagai pengukuran desktop dan tidak diekstrapolasi menjadi klaim tablet; aplikasi merekam latensi aktual setiap sesi.


Rincian studi degradasi. Citra sumber tidak memuat timestamp, sehingga eksperimen 30 Hz adalah sparsifikasi piksel dan tidak boleh ditafsirkan sebagai *temporal resampling*. Kondisi gabungan yang meniru perangkat sasaran adalah proxy 30 Hz ditambah derau $1,5^\circ$, dropout 20 persen, dan jitter pose 2° . Jitter pose sampai 3° nyaris tidak berpengaruh pada kedua set; pada proxy 120 Hz set penuh masih unggul dan pada 60 Hz keduanya bersilangan.

Tabel 9: Ketahanan set fitur terhadap proxy degradasi, AUC tingkat anak. Kondisi gabungan meniru perangkat sasaran. Seluruh angka berasal dari `research/hasil/degradasi.json`.


Kondisi	13 geometri	19 penuh	Selisih
Bersih (250 Hz)	0,8228	0,8324	-0,0096
Derau $1,5^\circ$	0,8082	0,8187	-0,0105
Derau 3°	0,7569	0,7724	-0,0155
Dropout 30%	0,8054	0,8255	-0,0201
Jitter pose 3°	0,8214	0,8356	-0,0142
Proxy 60 Hz	0,7404	0,7321	+0,0083
Proxy 30 Hz	0,6882	0,6259	+0,0623
Gabungan proxy tablet	0,6827	0,6049	+0,0778

Tabel 10: Posisi setiap tingkat validasi terhadap lingkup makalah ini. Kolom bukti hanya memuat artefak yang ada di repositori.

Tingkat	Yang diuji	Bukti yang ada	Status
Algoritmik	generalisasi ke anak baru	AUC 0,8228 pada uji tertahan, 54 anak	tuntas
A	instrumen pada dewasa	100 sesi, 25 peserta, galat median $2,2^\circ$	lulus
B	agreement vs WebGazer.js	30 pasangan, 27 siap, AOI 99,7118%	lulus
C	skrining pada balita	bukti sekunder; kohort prospektif belum ada	terbuka
D	operasional Posyandu	protokol tersedia; uji lapangan belum ada	terbuka



Gambar 4: Titik kerja model riset Carette pada 54 anak domain sumber. (a) ambang dari target sensitivitas 0,9; (b) titik kerja seimbang menurut indeks Youden; (c) sensitivitas, spesifisitas, dan fraksi anak yang dirujuk sebagai fungsi ambang, dengan garis titik menandai kedua titik kerja.



Gambar 5: Scanpath anak yang salah diklasifikasikan pada titik kerja seimbang, dengan prediksi benar sebagai pembandingan. Nilai tinta adalah fraksi piksel yang dilewati lintasan. Kesalahan terkonsentrasi pada rekaman dengan cakupan ekstrem di kedua arah.

Lampiran F. Titik kerja dan scanpath anak yang salah diklasifikasikan


Lampiran G. Rincian praproses, fitur, model, dan protokol evaluasi

Lampiran ini memuat rincian yang diringkas pada Bagian 2.3.

Praproses sinyal pandangan

Antara video mentah dan matriks fitur ada tujuh tahap, seluruhnya berjalan di perangkat (modul gaze/pipeline.ts).

- Deteksi wajah dan iris.** MediaPipe Face Landmarker mengeluarkan 478 landmark per frame; pusat iris diproyeksikan ke kerangka koordinat lokal mata yang dibentuk kedua sudut kelopak, sehingga kemiringan kepala tidak terbaca sebagai perubahan arah pandang.
- Kalibrasi ke koordinat layar.** Sinyal iris (u, v) dipetakan ke layar ternormalisasi lewat regresi affine per sumbu pada grid minimal tujuh posisi, ditutup koreksi drift dari target pusat. Galatnya dilaporkan dalam derajat sebagai syarat lulus tersendiri.
- Penapisan sampel.** Sampel non-finit, sampel di luar margin layar 0,12, dan lompatan lebih dari 0,65 satuan layar dibuang sebelum apa pun dihitung.
- Segmentasi deret.** Jeda di atas 180 ms, pergantian fase stimulus, atau pergantian epoch memutus deret. Penghalusan yang menjembatani batas ini akan menciptakan sakade yang tidak pernah terjadi.



Gambar 6: Alur penelitian Neurogaze. Pemilihan fitur, model, dan ambang seluruhnya terjadi pada tahap 4 memakai lipatan dalam; lipatan uji tertahan hanya dibaca pada tahap 5 dan 6. Audit dataset wajah pada Lampiran D berjalan di luar alur ini dan tidak menyumbang bobot, fitur, maupun keputusan apa pun ke model riset Carette.

5. **Penghalusan dan resampling.** Rerata bergerak eksponensial ($\alpha = 0,42$) per segmen, lalu re-sample 50 ms agar laju frame yang berfluktuasi tidak mengubah bobot tiap wilayah layar.
6. **Pemetaan area minat.** Atlas AOI membagi layar menjadi wajah, target kiri, target kanan, dan latar, sehingga okupansi serta latensi respons terhitung per fase.
7. **Rasterisasi.** Deret (x, y, t) dirender menjadi raster 640×480 mengikuti konvensi Carette, supaya fitur dihitung pada representasi yang sama dengan data pelatihan.

Dua kelompok fitur scanpath

Sembilan belas fitur yang dihitung dari raster terbelah menurut satu hal: apakah fitur itu membaca warna atau tidak.

- *Tiga belas fitur geometri* hanya membaca posisi piksel bertinta, terbagi lima kelompok: *cakupan* (ink_frac, n_active_cells, bbox_fill), *dispersi* (std_x, std_y, span_x, span_y, aspect_ratio), *pusat perhatian* (centroid_x, centroid_y), *jarak radial* (radial_mean, radial_std), dan *entropi* sebaran pada grid 8×8 (grid_entropy).
- *Enam fitur kinematik* membaca kanal warna: rerata dan simpangan baku kecepatan dari kanal R, rerata akselerasi dari G, rerata jerk dari B, serta rasio fiksasi dan sakade dari perbandingan antar-kanal. Turunan tinggi menguatkan derau pada sampling rendah, jadi kelayakannya di kamera 30 fps harus diputuskan lewat pengukuran.

Keluarga model yang diuji

Lima keluarga model tabular kami uji pada kedua set fitur, ditambah satu jalur citra sebagai pembanding representasi. Semuanya memakai pemisahan berkelompok yang sama.

- **Regresi logistik** (ditetapkan sebagai model utama sebelum melihat hasil): standardisasi fitur lalu LogisticRegression, max_iter 5000. Dipilih karena inferensinya cuma perkalian titik, koefisiennya dapat diekspor apa adanya ke model.json, dan kontribusi tiap fitur bisa diperiksa satu per satu.
- **SVM kernel RBF**: batas keputusan non-linier tanpa menaikkan jumlah parameter, tetapi keluarganya bukan probabilitas dan bobotnya tidak terbaca manusia.

- **Gaussian Naive Bayes:** baseline yang berguna justru karena asumsi independensinya jelas salah pada fitur cakupan yang saling berkorelasi.
- **Random Forest** dan **Gradient Boosting:** ansambel pohon yang menangkap interaksi antar-fitur, dengan risiko menghafal pada 54 partisipan dan ukuran artefak jauh di atas anggaran aset luring.
- **CNN EfficientNetB0** [22] *transfer learning* pada citra scanpath: bobot ImageNet, backbone dibekukan untuk 20 epoch pelatihan head (*global average pooling*, dropout 0,35, satu neuron sigmoid), lalu 12 epoch fine-tuning pada 25 persen lapisan teratas, dengan augmentasi rotasi, translasi, zoom, dan kontras ringan. Bobot sampelnya *equal-child*, yaitu bobot kelas dibagi jumlah rekaman anak, agar anak dengan 23 rekaman tidak 23 kali lebih berpengaruh.

Kalibrasi probabilitas dan pemilihan titik kerja

Skor mentah pengklasifikasi bukan probabilitas, dan alat skrining yang menampilkan angka kepada kader wajib dikalibrasi lebih dulu.

- **Platt scaling** pada logit skor, dipasang hanya pada lipatan validasi, dengan bobot sampel invers terhadap jumlah rekaman per anak agar partisipan produktif tidak menyetir kalibrator.
- **Diagnostik kalibrasi** berupa skor Brier dan kemiringan kalibrasi; kemiringan di atas satu menandakan probabilitas yang terlalu berhati-hati.
- **Ambang target sensitivitas**, yaitu ambang empiris terbesar yang masih memberi sensitivitas minimal 0,9 pada lipatan validasi, dengan stabilitas diperiksa lewat bootstrap.
- **Indeks Youden** sebagai titik kerja pembandingan, dilaporkan berdampingan agar konsekuensi pilihan ambang terlihat.

Protokol evaluasi berkelompok dan uji ketahanan

Satu anak menyumbang banyak rekaman, sehingga metode evaluasi menentukan apakah angkanya berarti.

- **GroupKFold bersarang** dengan `participant_id` sebagai grup: lima lipatan luar untuk uji tertahan, empat lipatan dalam untuk kalibrasi dan ambang.
- **Agregasi ke tingkat anak** dengan merata-ratakan probabilitas rekaman, karena unit keputusan produk adalah anak.
- **Bootstrap yang meresampel anak**, bukan citra, agar lebar interval kepercayaan mencerminkan 54 dan bukan 547.
- **Kontrol negatif kebocoran:** pipeline yang sama dijalankan ulang dengan unit pengelompokan diganti, lalu penyeberangan batas split dihitung.
- **Studi degradasi** berupa derau posisi, sparsifikasi raster sebagai proxy laju sampling, dropout, dan jitter pose, untuk memperkirakan performa pada perangkat sasaran sebelum perangkatnya tersedia.